Haute école de gestion
Genève

Exploration des concepts et des techniques d'apprentissage par renforcement : De la théorie à la pratique

Travail de Master réalisé en vue de l'obtention du Master of Science HES-SO en Sciences de l'information par :

David Paulino

Conseillers au travail de Master :

Pr Alexandros KALOUSIS

Genève, le 17 mars 2026

Haute école de Gestion de Genève (HEG-GE)

Filière Information Science

Hes·so
Haute Ecole Spécialisée
de Suisse occidentale

1 Déclaration

Ce travail de Master est réalisé dans le cadre du Master en Sciences de l'information de la Haute école de gestion de Genève.

L'étudiant-e atteste que le travail rendu est le fruit de sa réflexion personnelle, a été rédigé de manière autonome sans avoir utilisé des sources autres que celles citées dans la bibliographie et a été vérifié par un logiciel de détection de plagiat.

L'étudiant-e accepte, le cas échéant, la clause de confidentialité.

L'utilisation des conclusions et recommandations formulées dans ce travail, sans préjuger de leur valeur, n'engage ni la responsabilité de l'étudiant-e, ni celle du-de la directeur-trice.

Fait à Genève, le 17 mars 2026

David Paulino

2 Remerciements

La partie où on remercie les gens qui nous ont aidé à réaliser ce travail de Master.

3 Résumé

Voilà le résumé de ce travail de Master. Il est important de bien résumer le travail pour que le lecteur puisse comprendre le contenu de ce travail sans avoir à le lire en entier.

Liste des tableaux

Table des figures

1 Boucle d'interaction agent-environnement en apprentissage par renforcement 9

2 Environnement Cliff Walking. 10

Table des matières

1 Déclaration **1**

2 Remerciements **2**

3 Résumé **3**

Liste des tableaux **4**

Table des figures **5**

4 Introduction **8**

5 État de l'art **9**

5.1 Le paradigme Agent-Environnement 9

5.1.1 Exemple : Cliff Walking 10

5.2 Spécificités et Concepts Clés 10

5.3 Processus décisionnel de Markov (MDP) 11

5.4 Model-Based 11

5.4.1 Policy Evaluation et Policy Iteration 12

5.4.2 Value Iteration 13

5.5 Model-Free 14

6 Méthodologie **14**

7 Résultats **14**

7.1 Sous-section des résultats 14

7.1.1 Sous-sous-section des résultats 14

8 Conclusion **14**

4 Introduction

Parmi les paradigmes de l'apprentissage automatique, l'apprentissage par renforcement (*Reinforcement Learning*, RL) se distingue par sa capacité à former des agents autonomes via l'interaction directe avec leur environnement (Sutton et al., 2015). Contrairement à l'apprentissage supervisé, le RL repose sur un processus d'essais et erreurs : l'agent ajuste sa *politique* de décision en fonction d'un signal de récompense, avec pour objectif de maximiser ses bénéfices cumulés.

Cette approche a prouvé son efficacité dans la maîtrise de jeux complexes (Zaffagni, 2022 ; *OpenAI Five*, 2018), la robotique (Tang et al., 2024) ou encore l'optimisation de recommandations (Iftikhar et al., 2024). Néanmoins, son application pratique soulève des défis majeurs, tels que l'efficacité d'échantillonnage (*sample efficiency*), la conception des fonctions de récompense et l'équilibre entre exploration et exploitation.

5 État de l'art

Cette section présente les fondements théoriques de l'apprentissage par renforcement, en s'appuyant principalement sur les travaux de Sutton et al. (2015) et les leçons de Silver (2015).

5.1 Le paradigme Agent-Environnement

Le cadre fondamental du RL repose sur une boucle d'interaction continue entre deux entités (voir Figure 1) :

— **L'agent** : l'entité décisionnelle qui apprend et agit.

— **L'environnement** : le monde extérieur avec lequel l'agent interagit.

À chaque pas de temps discret t, l'interaction suit la séquence suivante :

1. L'agent reçoit une **observation** O_t et une **récompense** R_t.
2. L'agent sélectionne une **action** A_t en fonction de sa politique actuelle.
3. L'environnement réagit à cette action, transite vers un nouvel état et génère une nouvelle récompense R_{t+1} ainsi qu'une nouvelle observation O_{t+1}.

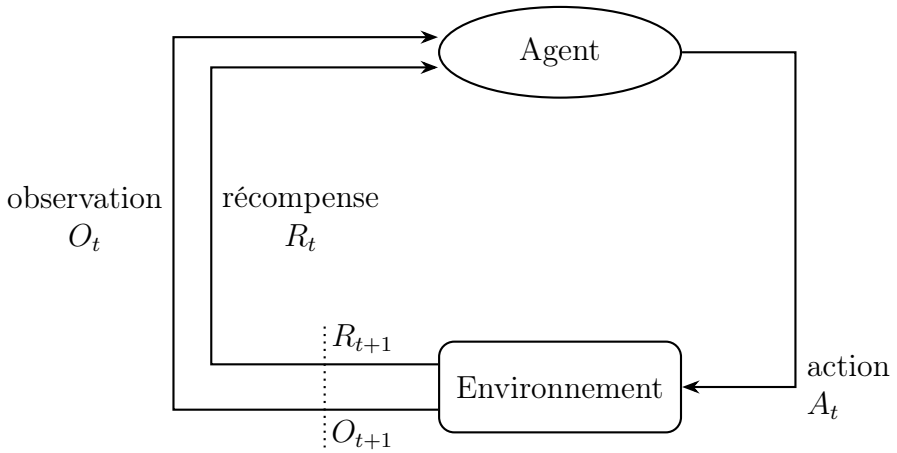

FIGURE 1 – Boucle d'interaction agent-environnement en apprentissage par renforcement

5.1.1 Exemple : Cliff Walking

L'environnement *Cliff Walking*[1] (Figure 2) illustre ces mécanismes. L'agent navigue sur une grille pour atteindre une cible en évitant une falaise. Il reçoit une récompense de -1 par pas parcouru (pour inciter à la rapidité) et de -100 avec retour au départ s'il tombe. Cet exemple met en évidence un compromis classique : l'agent doit équilibrer de la minimisation de la distance pénalisante tout en évitant un risque majeur.

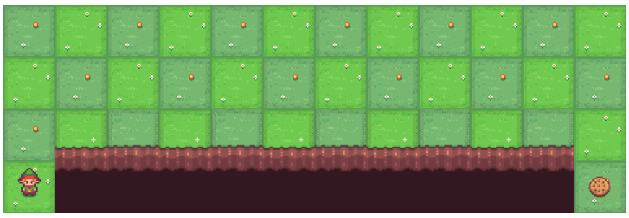

FIGURE 2 – Environnement Cliff Walking.

5.2 Spécificités et Concepts Clés

Le RL se caractérise par l'absence d'expert superviseur (seul le signal de récompense compte), des *feedbacks* souvent différés soulignant le problème de l'assignation de crédit, et des données fortement corrélées temporellement (non i.i.d.).

Afin de formaliser ce problème, nous définissons les éléments fondamentaux de la boucle d'interaction (Sutton et al., 2015) :

— **Historique et État (S_t)** : L'historique regroupe les observations, actions et récompenses passées. L'état S_t est l'information retenue par l'agent à l'instant t pour dicter son comportement futur. (idéalement porteur de la *propriété de Markov*).
— **Action (A_t)** : Décision prise par l'agent dans un état donné, pouvant appartenir à un espace discret ou continu.
— **Récompense (R_{t+1})** : Signal scalaire émis par l'environnement quantifiant la validité immédiate de l'action effectuée.

1. `https://gymnasium.farama.org/environments/toy_text/cliff_walking/`

— **Politique (π)** : Stratégie propre à l'agent. Elle peut être déterministe ($a = \pi(s)$) ou stochastique ($\pi(a|s) = P(A_t = a|S_t = s)$).
— **Fonction de valeur (V^π, Q^π)** : Mesure l'espérance des retours cumulatifs (les gains sur le long terme) à partir d'un état ou d'une paire état-action.

5.3 Processus décisionnel de Markov (MDP)

L'environnement d'apprentissage est formellement modélisé par un Processus Décisionnel de Markov (MDP). Ce cadre mathématique repose sur la **propriété de Markov** : l'état S_t suffit à prédire la dynamique du système, indépendamment de toute l'histoire passée ($P(S_{t+1}|S_t) = P(S_{t+1}|H_t)$).

Un MDP est défini par le quintuplet $(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma)$:
— $\mathcal{S}$ et $\mathcal{A}$: les ensembles d'états et d'actions possibles.
— $\mathcal{P}^a_{ss'} = \mathbb{P}[S_{t+1} = s'|S_t = s, A_t = a]$: la probabilité de transition d'un état s à un état s' sous l'action a.
— $\mathcal{R}^a_s = \mathbb{E}[R_{t+1}|S_t = s, A_t = a]$: la récompense espérée pour l'action a dans l'état s.
— $\gamma \in [0, 1]$: le facteur d'actualisation (*discount factor*), où un γ proche de 0 induit un agent myope aux gains immédiats, tandis qu'un γ proche de 1 privilégie le long terme.

Ce modèle vise à optimiser un **retour cumulé** G_t, somme des récompenses actualisées :

$$G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \tag{1}$$

5.4 Model-Based

Pour comprendre les méthodes d'apprentissage par renforcement, il est essentiel de distinguer les approches *model-based* et *model-free*. Les premières reposent sur la connaissance explicite des dynamiques de l'environnement ($\mathcal{P}$ et $\mathcal{R}$), tandis que les secondes apprennent directement à partir des interactions sans modéliser ces dynamiques. En connaissant les dynamiques du système, ces méthodes permettent de planifier efficacement les actions fu-

tures, en évaluant les conséquences de chaque décision avant de l'exécuter. Ainsi, l'agent n'a pas besoin d'apprendre par essais et erreurs, mais peut calculer la meilleure stratégie à partir de sa compréhension du monde.

5.4.1 Policy Evaluation et Policy Iteration

La *Policy Iteration* alterne deux opérations complémentaires :

1. **Policy Evaluation** : estimer la qualité de la politique courante π via V^π.
2. **Policy Improvement** : construire une politique améliorée en choisissant, dans chaque état, l'action la plus prometteuse selon cette estimation. C'est l'idée de la règle *greedy*.

L'idée centrale est simple : **évaluer puis améliorer**, jusqu'à stabilisation de la politique. Ce processus itératif garantit la convergence vers une politique optimale π^*, pour laquelle $V^{\pi^*} \geq V^\pi$ pour toute politique π (Silver, 2015).

Rôle de la Policy Evaluation

Évaluer une politique revient à estimer l'espérance du retour cumulé si l'agent suit toujours π. Cette estimation se fait itérativement à partir d'une initialisation (par exemple $V_0(s) = 0$) :

$$V_{k+1}(s) = \sum_{a \in \mathcal{A}} \pi(a|s) \left[\mathcal{R}_s^a + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}_{ss'}^a V_k(s') \right] \tag{2}$$

Chaque itération propage l'information de récompense dans l'espace d'états. En théorie, $V_k \to V^\pi$ lorsque $k \to \infty$.

Utilisation d'une approximation en pratique

En pratique, l'objectif n'est pas seulement d'estimer parfaitement V^π, mais de trouver une meilleure politique. Or, quelques itérations d'évaluation donnent souvent une approximation déjà suffisante pour orienter correctement l'étape *greedy*.

On améliore alors la politique avec :

$$\pi'(s) = \arg\max_{a \in \mathcal{A}} q_\pi(s, a) \tag{3}$$

Si cette politique change, on recommence l'itération *évaluation et amélioration* ; sinon, on s'arrête. Cette logique correspond à l'**itération de la politique modifiée** : on remplace une évaluation exacte par une évaluation partielle (nombre fixe d'itérations ou seuil ϵ), ce qui réduit fortement le coût de calcul sans perdre l'intuition de l'algorithme.

5.4.2 Value Iteration

La *Value Iteration* cherche directement la valeur optimale V^*, sans stocker de politique explicite pendant l'apprentissage. Elle fusionne donc l'évaluation et l'amélioration en une seule mise à jour basée sur l'opérateur **maximum**.

Principe de mise à jour

$$V_{k+1}(s) = \max_{a \in \mathcal{A}} \left[\mathcal{R}_s^a + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}_{ss'}^a V_k(s') \right] \tag{4}$$

À chaque itération, la valeur d'un état est réévaluée en supposant l'action future la plus favorable. En pratique, on arrête lorsque les variations deviennent faibles (par exemple $\max_s |V_{k+1}(s) - V_k(s)| < \epsilon$), ce qui donne une approximation suffisante pour décider.

Lien avec la Policy Iteration et extraction de π^*

La *Value Iteration* peut être vue comme une *Modified Policy Iteration*, où l'évaluation de politique est réduite à une seule mise à jour avant amélioration. Une fois V stabilisée, on extrait la politique optimale par une règle *greedy* :

$$\pi^*(s) = \arg\max_{a \in \mathcal{A}} \left[\mathcal{R}_s^a + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}_{ss'}^a V^*(s') \right] \tag{5}$$

5.5 Model-Free

L'utilisation réel du RL se fait souvent dans des environnements complexes où les dynamiques sont inconnues ou difficiles à modéliser. On ne connaît donc pas les fonctions de transition $\mathcal{P}$ ni de récompense $\mathcal{R}$, ce qui rend les méthodes *model-based* inapplicables. Les méthodes *model-free* apprennent directement à partir des expériences d'interaction, en estimant les fonctions de valeur ou en optimisant la politique sans modéliser explicitement l'environnement. C'est concrètement ce que Silver (2015) appelle *learning* plutôt que *planning*[2].

6 Méthodologie

7 Résultats

7.1 Sous-section des résultats

7.1.1 Sous-sous-section des résultats

8 Conclusion

Références

IFTIKHAR, Arta ; GHAZANFAR, Mustansar Ali ; AYUB, Mubbashir ; ALI ALAHMARI, Saad ; QAZI, Nadeem ; WALL, Julie, 2024. A Reinforcement Learning Recommender System Using Bi-Clustering and Markov Decision Process. *Expert Systems with Applications* [en ligne]. T. 237, p. 121541 [visité le 2026-02-23]. ISSN 0957-4174. Disp. à l'adr. DOI : `10.1016/j.eswa.2023.121541`.

2. Lié aux méthodes *model-based*

OpenAI Five, 2018 [en ligne]. 2018-06-25. [visité le 2026-02-23]. Disp. à l'adr.: https://openai.com/index/openai-five/.

SILVER, David, 2015. *Lectures on Reinforcement Learning*.

SUTTON, Richard S; BARTO, Andrew G, 2015. Reinforcement Learning: An Introduction.

TANG, Chen ; ABBATEMATTEO, Ben ; HU, Jiaheng ; CHANDRA, Rohan ; MARTÍN-MARTÍN, Roberto ; STONE, Peter, 2024. *Deep Reinforcement Learning for Robotics : A Survey of Real-World Successes* [en ligne]. 2024-09-16. [visité le 2026-02-23]. Disp. à l'adr. DOI : 10.48550/arXiv.2408.03539.

ZAFFAGNI, Marc, 2022. *Définition | AlphaGo : qu'est-ce que c'est ? | Futura tech* [en ligne]. Futura, 2022-12-01. [visité le 2026-02-23]. Disp. à l'adr. : https://www.futura-sciences.com/tech/definitions/intelligence-artificielle-alphago-16467/.