Haute école de gestion
Genève

Exploration des concepts et des techniques d'apprentissage par renforcement : De la théorie à la pratique

Travail de Master réalisé en vue de l'obtention du Master of Science HES-SO en Sciences de l'information par :

David Paulino

Conseillers au travail de Master :

Pr Alexandros KALOUSIS

Genève, le 4 mars 2026

Haute école de Gestion de Genève (HEG-GE)

Filière Information Science

Hes·so
Haute Ecole Spécialisée
de Suisse occidentale

1 Déclaration

Ce travail de Master est réalisé dans le cadre du Master en Sciences de l'information de la Haute école de gestion de Genève.

L'étudiant-e atteste que le travail rendu est le fruit de sa réflexion personnelle, a été rédigé de manière autonome sans avoir utilisé des sources autres que celles citées dans la bibliographie et a été vérifié par un logiciel de détection de plagiat.

L'étudiant-e accepte, le cas échéant, la clause de confidentialité.

L'utilisation des conclusions et recommandations formulées dans ce travail, sans préjuger de leur valeur, n'engage ni la responsabilité de l'étudiant-e, ni celle du-de la directeur-trice.

Fait à Genève, le 4 mars 2026

David Paulino

2 Remerciements

La partie où on remercie les gens qui nous ont aidé à réaliser ce travail de Master.

3 Résumé

Voilà le résumé de ce travail de Master. Il est important de bien résumer le travail pour que le lecteur puisse comprendre le contenu de ce travail sans avoir à le lire en entier.

Liste des tableaux

Table des figures

1 Boucle d'interaction agent-environnement en apprentissage par renforcement 9

2 Environnement de Cliff Walking : l'agent doit atteindre la cible en évitant la falaise. 10

Table des matières

1 Déclaration **1**

2 Remerciements **2**

3 Résumé **3**

Liste des tableaux **4**

Table des figures **5**

4 Introduction **8**

5 Introduction **8**

6 État de l'art **9**

6.1 Le paradigme Agent-Environnement 9

6.1.1 Exemple illustratif : Cliff Walking 10

6.2 Distinction entre État et Historique 11

6.3 Caractéristiques distinctives 11

6.4 Définitions des concepts clés 12

6.5 Processus décisionnel de Markov (MDP) 13

6.5.1 Propriété de Markov 13

6.5.2 Matrice de transition d'état 13

6.5.3 Processus de Markov 14

6.5.4 Processus de récompense de Markov (MRP) 14

6.5.5 Retour 14
6.5.6 Fonction de valeur (Value function) 15
6.5.7 Equation de Bellman 15
6.5.8 Processus de décision de Markov (MDP) 16
6.5.9 Fonction de valeur d'action (Q-function) 16
6.5.10 Équations d'optimalité de Bellman 17

7 Méthodologie **18**

8 Résultats **18**

8.1 Sous-section des résultats 18
8.1.1 Sous-sous-section des résultats 18

9 Conclusion **18**

4 Introduction

5 Introduction

L'intelligence artificielle a connu des avancées spectaculaires ces dernières années, transformant de nombreux domaines allant de la vision par ordinateur au traitement automatique des langues. Parmi les différents paradigmes de l'apprentissage automatique, l'apprentissage par renforcement (Reinforcement Learning, RL) se distingue par sa capacité à permettre à des agents d'apprendre de manière autonome par interaction directe avec leur environnement.

L'apprentissage par renforcement constitue une branche de l'intelligence artificielle focalisée sur la prise de décision séquentielle. Contrairement à l'apprentissage supervisé, où les modèles sont entraînés sur des données étiquetées, le RL repose sur un processus d'apprentissage par essais et erreurs. L'agent ajuste sa stratégie — ou *politique* — en fonction d'un signal de récompense scalaire, avec pour objectif ultime de maximiser les bénéfices cumulés sur le long terme.

Cette approche a démontré son efficacité dans des domaines variés : de la maîtrise de jeux complexes (Zaffagni, 2022 ; *OpenAI Five*, 2018) à la robotique de précision (Tang et al., 2024), en passant par l'optimisation des systèmes de recommandation (Iftikhar et al., 2024). Ces succès illustrent le potentiel du RL pour résoudre des problèmes de contrôle et d'optimisation là où les méthodes traditionnelles ou supervisées atteignent leurs limites.

Toutefois, le passage de la théorie à la pratique soulève des défis majeurs. L'efficacité en termes d'échantillonnage (*sample efficiency*), la conception de fonctions de récompense alignées sur les objectifs réels, ainsi que l'équilibre délicat entre exploration et exploitation constituent des verrous scientifiques et techniques importants (Sutton et al., 2015).

6 État de l'art

Cette section présente les fondements théoriques de l'apprentissage par renforcement, en s'appuyant principalement sur les travaux de Sutton et al. (2015) et les leçons de Silver (2015).

6.1 Le paradigme Agent-Environnement

Le cadre fondamental du RL repose sur une boucle d'interaction continue entre deux entités (voir Figure 1) :

— **L'agent** : l'entité décisionnelle qui apprend et agit.

— **L'environnement** : le monde extérieur avec lequel l'agent interagit.

À chaque pas de temps discret t, l'interaction suit la séquence suivante :

1. L'agent reçoit une **observation** O_t et une **récompense** R_t.
2. L'agent sélectionne une **action** A_t en fonction de sa politique actuelle.
3. L'environnement réagit à cette action, transite vers un nouvel état et génère une nouvelle récompense R_{t+1} ainsi qu'une nouvelle observation O_{t+1}.

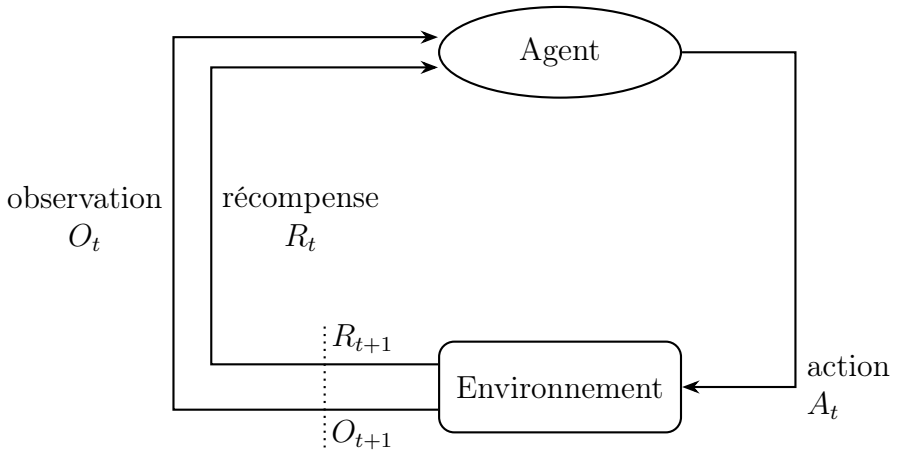

FIGURE 1 – Boucle d'interaction agent-environnement en apprentissage par renforcement

6.1.1 Exemple illustratif : Cliff Walking

Pour illustrer ces mécanismes, nous utiliserons l'environnement *Cliff Walking* (voir Figure 2).

Dans ce scénario, un agent doit naviguer sur une grille de 4×12 cases, d'un point de départ (en bas à gauche) vers une destination cible (en bas à droite). Entre ces deux points se situe une falaise (*cliff*). Le système de récompenses est conçu pour guider l'apprentissage de l'agent de la manière suivante :

- Une pénalité de -1 est attribuée pour chaque déplacement effectué, afin d'inciter l'agent à trouver le chemin le plus court.
- Une pénalité majeure de -100 est infligée si l'agent tombe dans la falaise. Dans ce cas, l'agent est instantanément replacé au point de départ pour recommencer sa tentative.

L'épisode[1] s'achève lorsque l'agent atteint la destination ou tombe dans la falaise.

Cet exemple met en évidence le dilemme de l'agent : il doit apprendre une stratégie qui minimise le nombre de pas tout en restant à une distance sécuritaire de la falaise. Une politique trop risquée (longer le bord) pourrait maximiser les gains mais présente un risque élevé de pénalité massive, tandis qu'une politique prudente (faire un détour par le haut) est plus sûre mais plus coûteuse en termes de récompenses par pas.

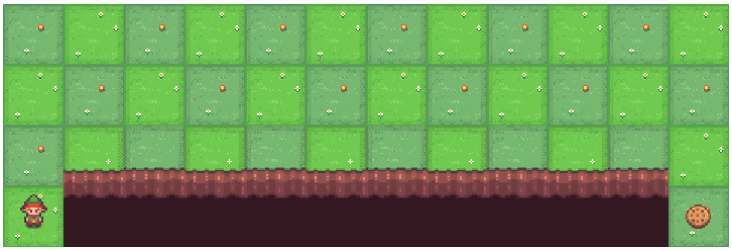

FIGURE 2 – Environnement de Cliff Walking : l'agent doit atteindre la cible en évitant la falaise.

1. Un épisode correspond à une séquence complète d'interactions, commençant au point de départ et se terminant lorsque l'agent atteint une condition de fin (ici, la destination ou la chute).

6.2 Distinction entre État et Historique

Il est crucial de distinguer la perception de l'agent de la réalité de l'environnement. L'**historique** H_t est la séquence complète des observations, actions et récompenses jusqu'au temps t :

$$H_t = O_0, A_0, R_1, O_1, \ldots, A_{t-1}, R_t, O_t \tag{1}$$

L'**état** est l'information utilisée pour déterminer ce qui se passera ensuite. On distingue généralement trois types d'états :

- **L'état de l'environnement** (S_t^e) : la configuration interne complète de l'environnement. Il est souvent invisible pour l'agent (ex : les cartes restantes dans le sabot au poker).
- **L'état de l'agent** (S_t^a) : la représentation interne que l'agent utilise pour choisir son action. C'est une fonction de l'historique : $S_t^a = f(H_t)$.
- **L'état d'information (ou état de Markov)** : un état qui contient toute l'information utile de l'historique.

6.3 Caractéristiques distinctives

Le RL se différencie des autres approches par trois aspects fondamentaux :

- **Absence de superviseur** : il n'y a pas d'expert pour indiquer l'action optimale ; seul un signal de récompense (souvent parcimonieux) guide l'agent.
- **Feedback différé** : une action prise à l'instant t peut n'avoir un impact sur la récompense qu'à l'instant $t + 100$. C'est le problème de l'assignation de crédit (*Credit Assignment Problem*).
- **Temps et séquentialité** : contrairement au *deep learning* classique, les données ne sont pas indépendantes et identiquement distribuées (i.i.d.). Les actions de l'agent influencent directement les données qu'il recevra ultérieurement.

6.4 Définitions des concepts clés

Afin de formaliser rigoureusement le problème d'apprentissage par renforcement, il convient de définir précisément les éléments constitutifs de cette boucle d'interaction (Sutton et al., 2015) :

- **Pas de temps** t : indice temporel discret marquant la progression de la séquence d'interactions. Chaque pas de temps correspond à un cycle complet d'observation-action-récompense.
- **État** S_t **(State)** : représentation complète de la situation de l'environnement à l'instant t. Un état doit idéalement contenir toute l'information nécessaire pour prendre une décision optimale (propriété de Markov). Par exemple, dans le jeu d'échecs, l'état correspond à la configuration complète du plateau.
- **Action** A_t : décision prise par l'agent à l'instant t parmi un ensemble d'actions possibles $\mathcal{A}(s)$ dans l'état s. L'espace d'actions peut être discret (gauche, droite, sauter) ou continu (angle de direction, force appliquée).
- **Récompense** R_{t+1} **(Reward)** : signal scalaire $R_{t+1} \in \mathbb{R}$ émis par l'environnement suite à l'action A_t dans l'état S_t. Cette valeur numérique quantifie la qualité immédiate de l'action effectuée (positive pour une bonne action, négative pour une mauvaise).
- **Politique** π **(Policy)** : stratégie de décision de l'agent, qui associe à chaque état une action ou une distribution de probabilité sur les actions.
  - **Politique déterministe** : $\pi(s) = a$ associe une action unique à chaque état. Il s'agit d'une fonction de décision stricte et prévisible.
  - **Politique stochastique** : $\pi(a|s) = P(A_t = a|S_t = s)$ définit une distribution de probabilité sur les actions possibles dans chaque état. Cette approche permet d'introduire de la diversité dans les comportements de l'agent.
- **Fonction de valeur** $V^\pi(s)$ **(Value function)** : espérance du retour cumulatif (somme des récompenses futures) que l'agent peut obtenir en partant de l'état s et en suivant la politique π. Cette fonction permet d'évaluer la qualité à long terme d'un état donné.
- **Modèle de l'environnement** : représentation (optionnelle) de la dynamique de l'environnement. Un modèle prédit l'état suivant S_{t+1} et la récompense R_{t+1} en fonction de l'état courant S_t et de l'action

choisie A_t. Les méthodes basées sur un modèle (model-based) utilisent cette connaissance, tandis que les méthodes sans modèle (model-free) apprennent directement à partir des interactions.

6.5 Processus décisionnel de Markov (MDP)

6.5.1 Propriété de Markov

Un concept central en apprentissage par renforcement est la **propriété de Markov**, qui stipule que l'état S_t doit contenir toute l'information nécessaire pour prédire les récompenses futures et les transitions d'état, indépendamment de l'historique complet des interactions passées. La propriété de Markov est formalisée par l'équation 2 :

$$P(S_{t+1}|S_t) = P(S_{t+1}|S_1, \ldots, S_t) = P(S_{t+1}|H_t) \tag{2}$$

Cela signifie que la probabilité de transition vers le prochain état S_{t+1} dépend uniquement de l'état courant S_t et est indépendante de tous les états précédents ou de l'historique complet H_t. Si l'environnement satisfait cette propriété, S_t contient toute l'information nécessaire pour déterminer la dynamique future. En pratique, on cherche à construire des représentations d'état qui respectent cette propriété afin de faciliter l'apprentissage de politiques efficaces.

6.5.2 Matrice de transition d'état

Dans un environnement de Markov, la dynamique de l'environnement peut être décrite par une matrice de transition d'état P, où chaque élément $P_{s,s'}$ représente la probabilité de transition de l'état s vers l'état s' suite à une action donnée. Cette matrice permet de modéliser la dynamique de l'environnement et de calculer les valeurs d'état et d'action nécessaires pour l'apprentissage de la politique optimale.

$$P_{s,s'} = P(S_{t+1} = s'|S_t = s, A_t = a) \tag{3}$$

Une matrice existe pour chaque action possible dans l'environnement, ce qui permet de modéliser la dynamique de manière complète. La dite matrice est

représentable également tel que sur l'équation 4 :

$$\mathcal{P}^a = \begin{bmatrix} \mathcal{P}_{s_1,s_1} & \mathcal{P}_{s_1,s_2} & \dots & \mathcal{P}_{s_1,s_n} \\ \mathcal{P}_{s_2,s_1} & \mathcal{P}_{s_2,s_2} & \dots & \mathcal{P}_{s_2,s_n} \\ \vdots & \vdots & \ddots & \vdots \\ \mathcal{P}_{s_n,s_1} & \mathcal{P}_{s_n,s_2} & \dots & \mathcal{P}_{s_n,s_n} \end{bmatrix} \tag{4}$$

6.5.3 Processus de Markov

Un processus de Markov (Markov Process, MP) est un modèle mathématique qui décrit un système évoluant dans le temps selon la propriété de Markov. Il s'agit d'un processus aléatoire sans mémoire régi sous forme de tuple $(\mathcal{S}, \mathcal{P})$:

- $\mathcal{S}$ est l'ensemble des états possibles
- $\mathcal{P}$ est la matrice de transition d'état

6.5.4 Processus de récompense de Markov (MRP)

Il est important de comprendre le processus de récompense de Markov, qui est une extension du processus de Markov (Markov Process, MP) en y intégrant un signal de récompense. Le MRP est donc un tuple $(\mathcal{S}, \mathcal{P}, \mathcal{R}, \gamma)$:

- $\mathcal{S}$ est l'ensemble des états possibles.
- $\mathcal{P}$ est la matrice de transition d'état.
- $\mathcal{R}$ est une fonction de récompense qui associe à chaque état une récompense scalaire.
- γ est le facteur d'actualisation $\gamma \in [0, 1]$.

6.5.5 Retour

Le **retour** (Return) est défini comme la somme des récompenses futures obtenues à partir d'un état donné, en suivant une politique spécifique. Il est généralement noté G_t et est formulé de la manière suivante (éq. 5) :

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \tag{5}$$

Le paramètre $\gamma \in [0, 1]$ représente le facteur d'actualisation (ou *discount factor*). Il agit comme une pondération définissant l'importance relative des récompenses futures vis-à-vis des gains immédiats. Ainsi, une valeur de γ tendant vers 0 indique que l'agent adopte une vision à court terme, tandis qu'un γ s'approchant de 1 traduit une stratégie orientée vers le long terme, l'agent valorisant davantage les récompenses cumulées.

L'utilisation d'un facteur d'actualisation est particulièrement importante dans un MDP ou un MRP. Tout d'abord, il permet d'empêcher que le retour soit infini s'il existe des cycles dans l'environnement qui génèrent des récompenses positives de manière répétée. Ensuite, il reflète la réalité selon laquelle les récompenses futures sont souvent moins certaines que les récompenses immédiates, ce qui incite l'agent à privilégier les gains à court terme tout en tenant compte des bénéfices à long terme. Enfin, il respecte la physiologie humaine, où les individus ont tendance à préférer des récompenses immédiates plutôt que des récompenses futures, même si ces dernières sont plus importantes.

6.5.6 Fonction de valeur (Value function)

La fonction de valeur de l'état d'un MRP est l'ésperance du retour en démarrant de l'état s et en suivant la politique π. Elle est notée $V^\pi(s)$ et est définie par l'équation 6 :

$$V^\pi(s) = \mathbb{E}_\pi[G_t | S_t = s] = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \middle| S_t = s \right] \tag{6}$$

Grâce à cette compréhension, on peut se pencher maintenant sur les équations de Bellman, qui sont fondamentales pour l'apprentissage de la politique optimale dans un MDP ou un MRP.

6.5.7 Equation de Bellman

L'équation de Bellman est une relation récursive qui exprime la fonction de valeur d'un état en fonction des récompenses immédiates et des valeurs des états suivants. Elle est formulée comme suit :

$$
\begin{aligned}
V^\pi(s) &= \mathbb{E}^\pi\left[G_t | S_t = s\right] \\
&= \mathbb{E}^\pi\left[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots \middle| S_t = s\right] \\
&= \mathbb{E}^\pi\left[R_{t+1} + \gamma(R_{t+2} + \gamma R_{t+3} + \dots) | S_t = s\right] \\
&= \mathbb{E}^\pi\left[R_{t+1} + \gamma G_{t+1} | S_t = s\right] \\
&= \mathbb{E}^\pi\left[R_{t+1} + \gamma V^\pi(S_{t+1}) | S_t = s\right]
\end{aligned} \tag{7}
$$

La décomposition de l'équation de Bellman met en évidence la nature récursive de la fonction de valeur, où la valeur d'un état est exprimée en fonction de la récompense immédiate et de la valeur des états suivants. Cette relation est fondamentale pour les algorithmes d'apprentissage par renforcement, car elle permet de mettre à jour les estimations de la fonction de valeur à partir des expériences accumulées par l'agent.

6.5.8 Processus de décision de Markov (MDP)

Un processus de décision de Markov (MDP) est un processus de récompense de Markov incluant des décisions. C'est l'environnement formel dans lequel l'apprentissage par renforcement opère. Il est défini par le quintuplet $(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma)$:

- $\mathcal{S}$ est l'ensemble des états possibles.
- $\mathcal{A}$ est l'ensemble des actions possibles.
- $\mathcal{P}$ est la matrice de probabilité de transition : $\mathcal{P}^a_{ss'} = \mathbb{P}[S_{t+1} = s' | S_t = s, A_t = a]$.
- $\mathcal{R}$ est la fonction de récompense : $\mathcal{R}^a_s = \mathbb{E}[R_{t+1} | S_t = s, A_t = a]$.
- γ est le facteur d'actualisation $\gamma \in [0, 1]$.

Dans ce cadre, la politique π ne dépend plus seulement de l'état, mais guide le choix de l'action. On note $\pi(a|s) = \mathbb{P}[A_t = a | S_t = s]$.

6.5.9 Fonction de valeur d'action (Q-function)

Alors que la fonction de valeur d'état $V^\pi(s)$ évalue la qualité d'un état, la fonction de valeur d'action $Q^\pi(s, a)$ (Action-Value Function) évalue la qualité d'une action spécifique prise dans un état donné, en suivant ensuite la politique π. Elle est définie par l'équation 8 :

$$Q^{\pi}(s,a) = \mathbb{E}_{\pi}[G_t | S_t = s, A_t = a] \tag{8}$$

Cette fonction Q est cruciale car elle permet à l'agent de comparer directement les actions possibles entre elles sans nécessairement connaître la dynamique du modèle (les probabilités de transition $\mathcal{P}$).

6.5.10 Équations d'optimalité de Bellman

L'objectif ultime de l'agent est de trouver la politique optimale π^* qui maximise le retour attendu. Cela nous amène aux fonctions de valeur optimales :

- $V^*(s) = \max_{\pi} V^{\pi}(s)$
- $Q^*(s,a) = \max_{\pi} Q^{\pi}(s,a)$

Contrairement aux équations de Bellman classiques qui sont linéaires, les équations d'optimalité de Bellman sont non-linéaires car elles impliquent l'opérateur max. Pour la fonction de valeur d'état, l'équation s'écrit :

$$V^*(s) = \max_{a \in \mathcal{A}} \left(\mathcal{R}_s^a + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}_{ss'}^a V^*(s') \right) \tag{9}$$

Et pour la fonction Q :

$$Q^*(s,a) = \mathcal{R}_s^a + \gamma \sum_{s' \in \mathcal{S}} \mathcal{P}_{ss'}^a \max_{a'} Q^*(s',a') \tag{10}$$

La résolution de ces équations constitue le cœur du problème de l'apprentissage par renforcement. Si l'agent connaît $Q^*(s,a)$, la politique optimale est simplement d'agir de manière "greedy" (avide) en choisissant systématiquement l'action a qui maximise $Q^*(s,a)$.

7 Méthodologie

8 Résultats

8.1 Sous-section des résultats

8.1.1 Sous-sous-section des résultats

9 Conclusion

Références

IFTIKHAR, Arta ; GHAZANFAR, Mustansar Ali ; AYUB, Mubbashir ; ALI ALAHMARI, Saad ; QAZI, Nadeem ; WALL, Julie, 2024. A Reinforcement Learning Recommender System Using Bi-Clustering and Markov Decision Process. *Expert Systems with Applications* [en ligne]. T. 237, p. 121541 [visité le 2026-02-23]. ISSN 0957-4174. Disp. à l'adr. DOI : `10.1016/j.eswa.2023.121541`.

OpenAI Five, 2018 [en ligne]. 2018-06-25. [visité le 2026-02-23]. Disp. à l'adr.: `https://openai.com/index/openai-five/`.

SILVER, David, 2015. *Lectures on Reinforcement Learning*.

SUTTON, Richard S; BARTO, Andrew G, 2015. Reinforcement Learning: An Introduction.

TANG, Chen ; ABBATEMATTEO, Ben ; HU, Jiaheng ; CHANDRA, Rohan ; MARTÍN-MARTÍN, Roberto ; STONE, Peter, 2024. *Deep Reinforcement Learning for Robotics : A Survey of Real-World Successes* [en ligne]. 2024-09-16. [visité le 2026-02-23]. Disp. à l'adr. DOI : `10.48550/arXiv.2408.03539`.

ZAFFAGNI, Marc, 2022. *Définition | AlphaGo : qu'est-ce que c'est ? | Futura tech* [en ligne]. Futura, 2022-12-01. [visité le 2026-02-23]. Disp. à l'adr. : `https://www.futura-sciences.com/tech/definitions/intelligence-artificielle-alphago-16467/`.