Haute école de gestion
Genève

Exploration des concepts et des techniques d'apprentissage par renforcement : De la théorie à la pratique

Travail de Master réalisé en vue de l'obtention du Master of Science HES-SO en Sciences de l'information par :

David Paulino

Conseillers au travail de Master :

Pr Alexandros KALOUSIS

Genève, le 2 mars 2026

Haute école de Gestion de Genève (HEG-GE)

Filière Information Science

Haute Ecole Spécialisée de Suisse occidentale

1 Déclaration

Ce travail de Master est réalisé dans le cadre du Master en Sciences de l'information de la Haute école de gestion de Genève.

L'étudiant-e atteste que le travail rendu est le fruit de sa réflexion personnelle, a été rédigé de manière autonome sans avoir utilisé des sources autres que celles citées dans la bibliographie et a été vérifié par un logiciel de détection de plagiat.

L'étudiant-e accepte, le cas échéant, la clause de confidentialité.

L'utilisation des conclusions et recommandations formulées dans ce travail, sans préjuger de leur valeur, n'engage ni la responsabilité de l'étudiant-e, ni celle du-de la directeur-trice.

Fait à Genève, le 2 mars 2026

David Paulino

2 Remerciements

La partie où on remercie les gens qui nous ont aidé à réaliser ce travail de Master.

3 Résumé

Voilà le résumé de ce travail de Master. Il est important de bien résumer le travail pour que le lecteur puisse comprendre le contenu de ce travail sans avoir à le lire en entier.

Liste des tableaux

Table des figures

1 Boucle d'interaction agent-environnement en apprentissage par renforcement 10

Table des matières

1 Déclaration **1**

2 Remerciements **2**

3 Résumé **3**

Liste des tableaux **4**

Table des figures **5**

4 Introduction **8**

5 État de l'art **9**

5.1 Concepts fondamentaux du RL 9

5.2 Caractéristiques distinctives du RL 11

5.3 Définitions des concepts clés 11

5.4 Processus décisionnel de Markov 13

5.4.1 Propriété de Markov 13

5.4.2 Matrice de transition d'état 13

6 Méthodologie **14**

7 Résultats **14**

7.1 Sous-section des résultats 14

7.1.1 Sous-sous-section des résultats 14

8 Conclusion **14**

4 Introduction

L'intelligence artificielle a connu des avancées spectaculaires ces dernières années, transformant de nombreux domaines allant de la reconnaissance d'images à la traduction automatique. Parmi les différentes approches de l'apprentissage automatique, l'apprentissage par renforcement (Reinforcement Learning, RL) se distingue par sa capacité à permettre aux agents d'apprendre de manière autonome à travers l'interaction avec leur environnement.

L'apprentissage par renforcement, souvent abrégé en RL (Reinforcement Learning), constitue une branche de l'intelligence artificielle qui se concentre sur la manière dont les agents peuvent apprendre à prendre des décisions optimales dans des environnements complexes. Contrairement à d'autres formes d'apprentissage automatique, où les modèles sont entraînés sur des données statiques, l'apprentissage par renforcement repose sur une interaction continue entre l'agent et son environnement. L'agent apprend par essais et erreurs successifs, recevant des récompenses ou des pénalités en fonction de ses actions, ce qui lui permet d'ajuster progressivement sa stratégie afin de maximiser les récompenses à long terme.

Cette approche a démontré son efficacité dans de nombreux domaines : des jeux vidéo (Zaffagni, 2022 ; *OpenAI Five*, 2018) à la robotique (Tang et al., 2024), en passant par l'optimisation des systèmes de recommandation (Iftikhar et al., 2024) et la gestion de ressources (Mao et al., 2016). Ces succès illustrent le potentiel du RL pour résoudre des problèmes complexes où les méthodes traditionnelles atteignent leurs limites.

Toutefois, malgré ces avancées prometteuses, l'apprentissage par renforcement présente plusieurs défis majeurs : la nécessité d'un nombre considérable d'interactions avec l'environnement (Sutton et al., 2014), la difficulté inhérente à la définition de fonctions de récompense appropriées selon l'environnement considéré, ainsi que la complexité de l'équilibre entre exploration et exploitation (Sutton et al., 2014). De plus, le passage de la théorie à la pratique soulève des questions méthodologiques et techniques importantes. Il convient également de noter que l'entraînement d'agents sur des environnements complexes tels que les jeux vidéo peut s'avérer particulièrement coûteux en termes de ressources computationnelles (*OpenAI Five*, 2018).

Ce travail de Master vise à explorer en profondeur les concepts fondamentaux et les techniques de l'apprentissage par renforcement, en établissant un pont entre les fondements théoriques et leurs applications pratiques. Plus spécifiquement, les objectifs de cette recherche sont les suivants :

- Présenter de manière systématique les concepts théoriques essentiels du RL (processus de décision de Markov, méthodes de Monte Carlo, différence temporelle, etc.)
- Analyser de façon critique les principales méthodes et algorithmes (Q-Learning, Deep Q-Networks, Policy Gradient, etc.)
- Mettre en œuvre ces techniques dans des cas pratiques afin d'évaluer empiriquement leur performance
- Identifier les bonnes pratiques méthodologiques ainsi que les écueils à éviter lors de l'implémentation

Ce document est structuré comme suit : la section 5 présente un état de l'art des techniques d'apprentissage par renforcement et de leurs applications. La section 6 décrit la méthodologie adoptée pour nos expérimentations. Les résultats obtenus sont analysés dans la section 7. Enfin, la section 8 synthétise les apports de ce travail et propose des perspectives de recherche futures.

5 État de l'art

Cette section présente les concepts fondamentaux et les techniques principales de l'apprentissage par renforcement. La majeure partie de cet état de l'art s'appuie sur les cours de David Silver (Silver, 2015) ainsi que sur l'ouvrage de référence de Sutton et Barto (Sutton et al., 2014), qui constituent les fondements théoriques de ce domaine.

5.1 Concepts fondamentaux du RL

L'apprentissage par renforcement met en scène deux acteurs principaux qui interagissent en permanence : un **agent** (le système apprenant) et un **environnement** (le monde dans lequel il évolue) (Sutton et al., 2014).

Le fonctionnement peut être décrit selon le processus itératif suivant :

1. L'agent observe l'état courant du système (l'**état** S_t)

2. Il sélectionne une **action** A_t à effectuer
3. L'environnement réagit en renvoyant une **récompense** R_{t+1} (une valeur scalaire indiquant la qualité de l'action effectuée)
4. L'environnement transite vers un nouvel état S_{t+1}
5. Le cycle se répète

La figure 1 illustre cette boucle d'interaction fondamentale.

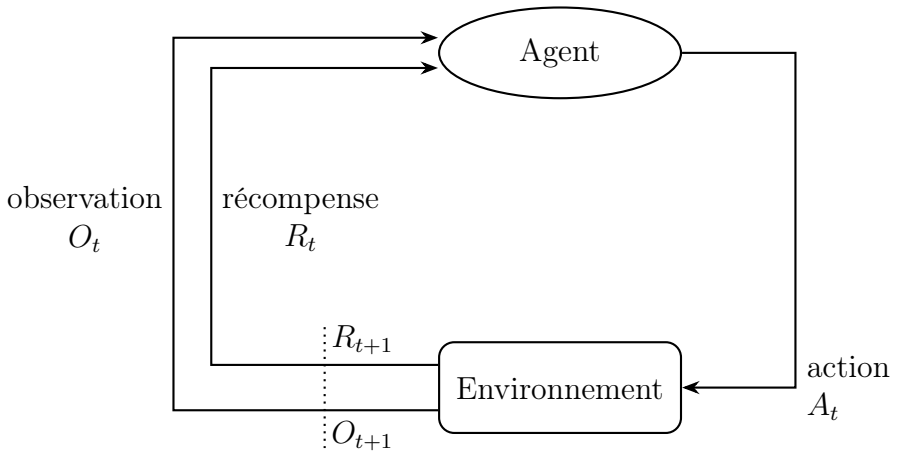

FIGURE 1 – Boucle d'interaction agent-environnement en apprentissage par renforcement

Au cours des interactions successives, l'agent accumule de l'expérience et apprend une **politique** π : une stratégie définissant l'action à sélectionner dans chaque situation donnée. À titre d'exemple, dans le contexte d'une partie d'échecs, la politique détermine le coup à jouer pour chaque configuration possible du plateau.

L'objectif de l'apprentissage consiste à identifier la politique optimale, c'est-à-dire celle permettant de maximiser l'espérance des récompenses cumulées sur l'ensemble de l'horizon temporel considéré. Cette subtilité est fondamentale : l'enjeu ne réside pas dans la maximisation de la récompense immédiate, mais bien dans celle des récompenses cumulées sur la totalité de la séquence.

5.2 Caractéristiques distinctives du RL

L'apprentissage par renforcement se distingue des autres paradigmes d'apprentissage automatique par plusieurs caractéristiques fondamentales (Silver, 2015) :

- **Absence de supervision directe** : contrairement à l'apprentissage supervisé où chaque exemple d'entraînement est associé à une cible y explicite, le RL ne dispose que d'un signal de récompense scalaire fourni par l'environnement, sans indication directe de l'action optimale à adopter.
- **Feedback différé** : les conséquences d'une action effectuée à l'instant t peuvent ne se manifester que plusieurs pas de temps ultérieurement, rendant particulièrement ardue l'attribution du crédit (Credit Assignment Problem) [1].
- **Nature séquentielle et interactive** : la dimension temporelle constitue une composante intrinsèque du problème. Les données ne sont pas indépendantes et identiquement distribuées (i.i.d), mais forment une séquence d'états, d'actions et de récompenses corrélés temporellement. Les actions de l'agent modifient l'état de l'environnement et influencent les observations et récompenses futures, créant ainsi une boucle de rétroaction continue.

5.3 Définitions des concepts clés

Afin de formaliser rigoureusement le problème d'apprentissage par renforcement, il convient de définir précisément les éléments constitutifs de cette boucle d'interaction (Sutton et al., 2014) :

- **Pas de temps** t : indice temporel discret marquant la progression de la séquence d'interactions. Chaque pas de temps correspond à un cycle complet d'observation-action-récompense.
- **État** S_t **(State)** : représentation complète de la situation de l'environnement à l'instant t. Un état doit idéalement contenir toute l'information nécessaire pour prendre une décision optimale (propriété

1. Le problème d'attribution du crédit consiste à déterminer quelles actions passées sont responsables des récompenses futures obtenues.

de Markov). Par exemple, dans le jeu d'échecs, l'état correspond à la configuration complète du plateau.
  - L'état S_t est représenté comme une fonction de l'historique complet des interactions passées : $S_t = f(H_t)$ [2]
- **Action** A_t : décision prise par l'agent à l'instant t parmi un ensemble d'actions possibles $\mathcal{A}(s)$ dans l'état s. L'espace d'actions peut être discret (gauche, droite, sauter) ou continu (angle de direction, force appliquée).
- **Récompense** R_{t+1} **(Reward)** : signal scalaire $R_{t+1} \in \mathbb{R}$ émis par l'environnement suite à l'action A_t dans l'état S_t. Cette valeur numérique quantifie la qualité immédiate de l'action effectuée (positive pour une bonne action, négative pour une mauvaise).
- **Politique** π **(Policy)** : stratégie de décision de l'agent, qui associe à chaque état une action ou une distribution de probabilité sur les actions.
  - **Politique déterministe** : $\pi(s) = a$ associe une action unique à chaque état. Il s'agit d'une fonction de décision stricte et prévisible.
  - **Politique stochastique** : $\pi(a|s) = P(A_t = a|S_t = s)$ définit une distribution de probabilité sur les actions possibles dans chaque état. Cette approche permet d'introduire de la diversité dans les comportements de l'agent.
- **Fonction de valeur** $V^\pi(s)$ **(Value function)** : espérance du retour cumulatif (somme des récompenses futures) que l'agent peut obtenir en partant de l'état s et en suivant la politique π. Cette fonction permet d'évaluer la qualité à long terme d'un état donné.
- **Modèle de l'environnement** : représentation (optionnelle) de la dynamique de l'environnement. Un modèle prédit l'état suivant S_{t+1} et la récompense R_{t+1} en fonction de l'état courant S_t et de l'action choisie A_t. Les méthodes basées sur un modèle (model-based) utilisent cette connaissance, tandis que les méthodes sans modèle (model-free) apprennent directement à partir des interactions.

2. $H_t = \{O_0, A_0, R_1, \ldots, O_{t-1}, A_{t-1}, R_t\}$.

5.4 Processus décisionnel de Markov

5.4.1 Propriété de Markov

Un concept central en apprentissage par renforcement est la **propriété de Markov**, qui stipule que l'état S_t doit contenir toute l'information nécessaire pour prédire les récompenses futures et les transitions d'état, indépendamment de l'historique complet des interactions passées. La propriété de Markov est formalisée par l'équation 1 :

$$P(S_{t+1}|S_t) = P(S_{t+1}|S_1, \ldots, S_t) = P(S_{t+1}|H_t) \tag{1}$$

Cela signifie que la probabilité de transition vers le prochain état S_{t+1} dépend uniquement de l'état courant S_t et est indépendante de tous les états précédents ou de l'historique complet H_t. Si l'environnement satisfait cette propriété, S_t contient toute l'information nécessaire pour déterminer la dynamique future. En pratique, on cherche à construire des représentations d'état qui respectent cette propriété afin de faciliter l'apprentissage de politiques efficaces.

5.4.2 Matrice de transition d'état

Dans un environnement de Markov, la dynamique de l'environnement peut être décrite par une matrice de transition d'état P, où chaque élément $P_{s,s'}$ représente la probabilité de transition de l'état s vers l'état s' suite à une action donnée. Cette matrice permet de modéliser la dynamique de l'environnement et de calculer les valeurs d'état et d'action nécessaires pour l'apprentissage de la politique optimale.

$$P_{s,s'} = P(S_{t+1} = s'|S_t = s, A_t = a) \tag{2}$$

Une matrice existe pour chaque action possible dans l'environnement, ce qui permet de modéliser la dynamique de manière complète. La dite matrice est

représentable également tel que sur l'équation 3 :

$$P^a = \begin{bmatrix} P_{s_1,s_1} & P_{s_1,s_2} & \dots & P_{s_1,s_n} \\ P_{s_2,s_1} & P_{s_2,s_2} & \dots & P_{s_2,s_n} \\ \vdots & \vdots & \ddots & \vdots \\ P_{s_n,s_1} & P_{s_n,s_2} & \dots & P_{s_n,s_n} \end{bmatrix} \tag{3}$$

6 Méthodologie

7 Résultats

7.1 Sous-section des résultats

7.1.1 Sous-sous-section des résultats

8 Conclusion

Références

IFTIKHAR, Arta ; GHAZANFAR, Mustansar Ali ; AYUB, Mubbashir ; ALI ALAHMARI, Saad ; QAZI, Nadeem ; WALL, Julie, 2024. A reinforcement learning recommender system using bi-clustering and Markov Decision Process. *Expert Systems with Applications* [en ligne]. T. 237, p. 121541 [visité le 2026-02-23]. ISSN 0957-4174. Disp. à l'adr. DOI : `10.1016/j.eswa.2023.121541`.

MAO, Hongzi; ALIZADEH, Mohammad; MENACHE, Ishai; KANDULA, Srikanth, 2016. Resource Management with Deep Reinforcement Learning. In: *Proceedings of the 15th ACM Workshop on Hot Topics in Networks* [en ligne]. Atlanta GA USA: ACM, p. 50–56 [visité le 2026-02-23]. ISBN 978-1-4503-4661-0. Disp. à l'adr. DOI: `10.1145/3005745.3005750`.

OpenAI Five, 2018 [en ligne]. 2018-06-25. [visité le 2026-02-23]. Disp. à l'adr.: `https://openai.com/index/openai-five/`.

SILVER, David, 2015. *Lectures on Reinforcement Learning*. Published : URL : https ://www.davidsilver.uk/teaching/.

SUTTON, Richard S; BARTO, Andrew G, 2014. Reinforcement Learning: An Introduction.

TANG, Chen ; ABBATEMATTEO, Ben ; HU, Jiaheng ; CHANDRA, Rohan ; MARTÍN-MARTÍN, Roberto ; STONE, Peter, 2024. *Deep Reinforcement Learning for Robotics : A Survey of Real-World Successes* [en ligne]. arXiv [visité le 2026-02-23]. N° arXiv :2408.03539. Disp. à l'adr. DOI : `10.48550/arXiv.2408.03539`.

ZAFFAGNI, Marc, 2022. *Définition | AlphaGo : qu'est-ce que c'est ? | Futura tech* [Futura] [en ligne]. 2022-12-01. [visité le 2026-02-23]. Disp. à l'adr. : `https://www.futura-sciences.com/tech/definitions/intelligence-artificielle-alphago-16467/`.