

Soutenance de mémoire - Master IS

David Paulino


21 août 2026

Plan de la présentation

- 1 Introduction
 - Contexte
 - Problématique
- 2 Fondations minimales
 - Boucle agent-environnement
 - Comparaison des algorithmes
- 3 Phase I
 - Méthodologie
 - Robustesse des configurations
- 4 Phase II
 - L'environnement Rocket League
 - Reward shaping et curriculum
 - Reward hacking
 - PPO vs SAC
 - Résultats
- 5 Limites et perspectives
 - Limites
 - Perspectives
- 6 Conclusion

Contexte

Rocket League : un jeu de football avec des voitures.



Question

Quelle est la probabilité qu'un agent agissant aléatoirement parvienne à marquer un but dans ce jeu ?

Quasi nulle.

Le problème du *reward sparse*

Ce phénomène porte un nom : le **reward sparse**

- Quand l'objectif final n'est atteint que rarement (voire jamais au début), l'agent ne reçoit presque aucun signal exploitable.
- Résultat : **absence totale d'apprentissage observable**, même après des millions de pas d'entraînement.

Problématique

Comment mener à bien l'apprentissage par renforcement dans un environnement à récompense rare, de la sélection et du réglage d'algorithmes standards jusqu'à la conception d'un signal de récompense pour un environnement avancé ?


Deux axes complémentaires :

- 1 **Sélection et optimisation des modèles** : quel algorithme choisir (DQN, PPO, SAC) selon l'environnement, et comment régler ses hyperparamètres ?
- 2 **Construction du signal de récompense** : comment densifier un signal rare sans dénaturer la tâche — et quel risque cela introduit ?

Démarche en deux phases

- ① **Phase I** — Validation méthodologique sur un environnement plus simple *LunarLander* : comparaison DQN / PPO / SAC, optimisation Optuna, robustesse multi-seeds.
- ② **Phase II** — Retour à **Rocket League** : reward shaping et curriculum learning pour surmonter la rareté structurelle du signal.

Boucle agent-environnement



Comparaison des algorithmes

Tableau comparatif des caractéristiques principales de DQN, PPO et SAC.

Caractéristique	DQN	PPO	SAC
Paradigme	Off-policy	On-policy	Off-policy
Espace d'actions	Discret	Les deux	Continu
Sample efficiency	Moyenne	Faible	Élevée

- **Environnement** : LunarLander
- **Algorithmes** : DQN, PPO, SAC
- **Optimisation** : Optuna pour le tuning des hyperparamètres
- **Évaluation** : Multi-seeds pour la robustesse

Score de tuning vs robustesse réelle

Combinaison	Score Optuna	Éval. finale (moy.)	Seeds résolues
DQN discret	275.14	145.19	1/5
PPO discret	278.76	218.58	3/5
PPO continu	280.42	208.67	2/5
SAC continu	284.05	233.44	4/5

Enseignement clé

Le score de tuning n'est **pas un prédicteur fiable** de la robustesse : DQN a un très bon score, mais la pire performance finale.

L'environnement Rocket League

- Simulation via **RocketSim** + **RLGym** : physique fidèle, entraînement *headless* (sans rendu graphique)
- Mode **1v1** : un agent affronte une copie de lui-même (*self-play*)
- Espace d'actions réduit par discrétisation : 1944 → **90** actions pertinentes
- Fréquence de décision ramenée de 120 Hz à **15 Hz** (*action repeat*)

Rappel

Le seul signal naturel — marquer un but — est **extrêmement rare** : aucun apprentissage observable en RL pur.

Reward shaping et curriculum

Palier	Objectif
I	Contrôle de base et contact avec la balle
II	Apprentissage du score (introduction du but)
III	Perfectionnement mécanique (boost, aérien, kickoff)

- **Reward shaping** : densifier le signal rare avec des signaux intermédiaires (contact, vitesse vers la balle...)
- **Curriculum learning** : introduire ces signaux progressivement, sans dégrader les acquis des paliers précédents

Une introduction simultanée de tous les signaux converge plus lentement.

Reward hacking



Reward hacking (suite)

Comportement observé

Les deux agents collaborent pour faire osciller la balle entre les deux buts, maximisant leur récompense individuelle sans jamais chercher à marquer.

Correction : reformulation en récompense *zero-sum* — le gain de l'un devient nécessairement la perte de l'autre

PPO vs SAC : une divergence marquée

- **PPO** : progresse de manière cohérente à travers tout le curriculum
- **SAC** : stagne dès le Palier I, entraînement interrompu

Deux facteurs explicatifs :

- ① Limites d'implémentation de `rlgym-sac` (pas de gradient clipping, cible d'entropie fixe)
- ② Espace d'actions **continu brut** (8 dimensions) contre l'espace **discret curaté** (90 actions) de PPO

Conclusion

Résultat non tranché : impossible de conclure à une infériorité intrinsèque de SAC sur cet environnement.

Résultats de l'agent PPO

- Victoires **3-0** contre Element (finaliste RLBot 2022)
- Victoires **3-0** contre Necto (vainqueur RLBot 2022, entraîné sur 3 modes de jeu et un budget supérieur)
- **6 victoires sur 9** contre des joueurs humains (Or à Champion)

Comportements émergents non récompensés explicitement :

- Gestion du boost plus économe qu'un joueur humain
- Utilisation systématique et précoce du *powerslide*

Références bibliographiques I

- AKIBA, Takuya ; SANO, Shotaro ; YANASE, Toshihiko ; OHTA, Takeru ; KOYAMA, Masanori, 2019. *Optuna : A Next-generation Hyperparameter Optimization Framework* [en ligne]. 2019-07-25. [visité le 04/05/2026]. Disp. à l'adr. DOI : 10.48550/arXiv.1907.10902.
- DAVID PAULINO, 2026. *Beep Boop v2 - Replays* [en ligne]. Ballchasing, 2026-07-01. [visité le 02/07/2026]. Disp. à l'adr. : <https://ballchasing.com/group/beep-boop-v2-10b-tdfuhcyooj>.
- FARAMA FOUNDATION, 2025. *Gymnasium Documentation - Lunar Lander* [en ligne]. [visité le 05/04/2026]. Disp. à l'adr.: https://gymnasium.farama.org/environments/box2d/lunar_lander.html.

Références bibliographiques II

HAARNOJA, Tuomas ; ZHOU, Aurick ; ABBEEL, Pieter ; LEVINE, Sergey, 2018. *Soft Actor-Critic : Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor* [en ligne]. 2018-08-08. [visité le 31/03/2026]. Disp. à l'adr. DOI : 10.48550/arXiv.1801.01290.

LITTMAN, Michael L., 1994. Markov Games as a Framework for Multi-Agent Reinforcement Learning. In : COHEN, William W. ; HIRSH, Haym (éd.). *Machine Learning Proceedings 1994* [en ligne]. San Francisco (CA) : Morgan Kaufmann, p. 157-163 [visité le 22/06/2026]. ISBN 978-1-55860-335-6. Disp. à l'adr. DOI : 10.1016/B978-1-55860-335-6.50027-1.

Références bibliographiques III

- MNIH, Volodymyr; KAVUKCUOGLU, Koray; SILVER, David; RUSU, Andrei A.; VENESS, Joel; BELLEMARE, Marc G.; GRAVES, Alex; RIEDMILLER, Martin; FIDJELAND, Andreas K.; OSTROVSKI, Georg; PETERSEN, Stig; BEATTIE, Charles; SADIK, Amir; ANTONOGLU, Ioannis; KING, Helen; KUMARAN, Dharshan; WIERSTRA, Daan; LEGG, Shane; HASSABIS, Demis, 2015. Human-Level Control through Deep Reinforcement Learning. *Nature* [en ligne]. Vol. 518, no. 7540, p. 529–533 [visité le 03/31/2026]. ISSN 1476-4687. Disp. à l'adr. DOI: 10.1038/nature14236.
- NARVEKAR, Sanmit; PENG, Bei; LEONETTI, Matteo; SINAPOV, Jivko; TAYLOR, Matthew E.; STONE, Peter, 2020. *Curriculum Learning for Reinforcement Learning Domains : A Framework and Survey* [en ligne]. 2020-09-17. [visité le 22/06/2026]. Disp. à l'adr. DOI : 10.48550/arXiv.2003.04960.

Références bibliographiques IV

SCHULMAN, John; WOLSKI, Filip; DHARIWAL, Prafulla;
RADFORD, Alec; KLIMOV, Oleg, 2017. *Proximal Policy Optimization Algorithms* [en ligne]. arXiv.org, 2017-07-20. [visit  le 03/31/2026].
Disp.   l'adr.: <https://arxiv.org/abs/1707.06347v2>.