

Soutenance de mémoire - Master IS

David Paulino

21 août 2026


Plan de la présentation

- 1 Introduction
- 2 Fondations minimales
- 3 Phase I
- 4 Phase II
- 5 Limites et perspectives
- 6 Conclusion

Introduction


Contexte

Rocket League : un jeu de football avec des voitures.



Contexte

Rocket League : un jeu de football avec des voitures.




Question

Quelle est la probabilité qu'un agent agissant aléatoirement parvienne à marquer un but dans ce jeu ?

Contexte

Rocket League : un jeu de football avec des voitures.



Question

Quelle est la probabilité qu'un agent agissant aléatoirement parvienne à marquer un but dans ce jeu ?

Quasi nulle.

Le problème du *sparse reward*

Ce phénomène porte un nom : le **sparse reward**

Ce phénomène porte un nom : le **sparse reward**

- Quand l'objectif final n'est atteint que rarement (voire jamais au début), l'agent ne reçoit presque aucun signal exploitable.

Ce phénomène porte un nom : le **sparse reward**

- Quand l'objectif final n'est atteint que rarement (voire jamais au début), l'agent ne reçoit presque aucun signal exploitable.
- Résultat : **absence totale d'apprentissage observable**, même après des millions de pas d'entraînement.

Problématique

Comment mener à bien l'apprentissage par renforcement dans un environnement à récompense rare, de la sélection et du réglage d'algorithmes standards jusqu'à la conception d'un signal de récompense pour un environnement avancé ?

Deux axes complémentaires :

Problématique

Comment mener à bien l'apprentissage par renforcement dans un environnement à récompense rare, de la sélection et du réglage d'algorithmes standards jusqu'à la conception d'un signal de récompense pour un environnement avancé ?

Deux axes complémentaires :

- 1 **Sélection et optimisation des modèles** : quel algorithme choisir (DQN, PPO, SAC) selon l'environnement, et comment régler ses hyperparamètres ?

Problématique

Comment mener à bien l'apprentissage par renforcement dans un environnement à récompense rare, de la sélection et du réglage d'algorithmes standards jusqu'à la conception d'un signal de récompense pour un environnement avancé ?

Deux axes complémentaires :

- ❶ **Sélection et optimisation des modèles** : quel algorithme choisir (DQN, PPO, SAC) selon l'environnement, et comment régler ses hyperparamètres ?
- ❷ **Construction du signal de récompense** : comment densifier un signal rare sans dénaturer la tâche — et quel risque cela introduit ?

Démarche en deux phases

① Phase I

Démarche en deux phases

- ① **Phase I** — Validation méthodologique sur un environnement plus simple *LunarLander* : comparaison DQN / PPO / SAC, optimisation Optuna, robustesse multi-seeds.

Démarche en deux phases


- ① **Phase I** — Validation méthodologique sur un environnement plus simple *LunarLander* : comparaison DQN / PPO / SAC, optimisation Optuna, robustesse multi-seeds.
- ② **Phase II**

Démarche en deux phases

- ① **Phase I** — Validation méthodologique sur un environnement plus simple *LunarLander* : comparaison DQN / PPO / SAC, optimisation Optuna, robustesse multi-seeds.
- ② **Phase II** — Retour à **Rocket League** : reward shaping et curriculum learning pour surmonter la rareté structurelle du signal.

Fondations minimales

Boucle agent-environnement



Comparaison des algorithmes

Tableau comparatif des caractéristiques principales de DQN, PPO et SAC.

Caractéristique	DQN	PPO	SAC
Paradigme	Off-policy	On-policy	Off-policy
Espace d'actions	Discret	Les deux	Continu
Sample efficiency	Moyenne	Faible	Élevée

Phase I

- **Environnement** : LunarLander
- **Algorithmes** : DQN, PPO, SAC
- **Optimisation** : Optuna pour le tuning des hyperparamètres
- **Évaluation** : Multi-seeds pour la robustesse

Score de tuning vs robustesse réelle

Combinaison	Score Optuna	Éval. finale (moy.)	Seeds résolues
DQN discret	275.14	145.19	1/5
PPO discret	278.76	218.58	3/5
PPO continu	280.42	208.67	2/5
SAC continu	284.05	233.44	4/5

Score de tuning vs robustesse réelle

Combinaison	Score Optuna	Éval. finale (moy.)	Seeds résolues
DQN discret	275.14	145.19	1/5
PPO discret	278.76	218.58	3/5
PPO continu	280.42	208.67	2/5
SAC continu	284.05	233.44	4/5

Enseignement clé

Le score de tuning n'est **pas un prédicteur fiable** de la robustesse : DQN a un très bon score, mais la pire performance finale.

Phase II

L'environnement Rocket League

- Simulation via **RocketSim** + **RLGym** : physique fidèle, entraînement *headless* (sans rendu graphique)
- Mode **1v1** : un agent affronte une copie de lui-même (*self-play*)
- Espace d'actions réduit par discrétisation : 1944 → **90** actions pertinentes
- Fréquence de décision ramenée de 120 Hz à **15 Hz** (*action repeat*)

L'environnement Rocket League

- Simulation via **RocketSim** + **RLGym** : physique fidèle, entraînement *headless* (sans rendu graphique)
- Mode **1v1** : un agent affronte une copie de lui-même (*self-play*)
- Espace d'actions réduit par discrétisation : 1944 → **90** actions pertinentes
- Fréquence de décision ramenée de 120 Hz à **15 Hz** (*action repeat*)

Rappel

Le seul signal naturel — marquer un but — est **extrêmement rare** : aucun apprentissage observable en RL pur.

Reward shaping et curriculum

Palier	Objectif
I	Contrôle de base et contact avec la balle
II	Apprentissage du score (introduction du but)
III	Perfectionnement mécanique (boost, aérien, kickoff)

Reward shaping et curriculum

Palier	Objectif
I	Contrôle de base et contact avec la balle
II	Apprentissage du score (introduction du but)
III	Perfectionnement mécanique (boost, aérien, kickoff)

- **Reward shaping** : densifier le signal rare avec des signaux intermédiaires (contact, vitesse vers la balle...)
- **Curriculum learning** : introduire ces signaux progressivement, sans dégrader les acquis des paliers précédents

Reward shaping et curriculum

Palier	Objectif
I	Contrôle de base et contact avec la balle
II	Apprentissage du score (introduction du but)
III	Perfectionnement mécanique (boost, aérien, kickoff)

- **Reward shaping** : densifier le signal rare avec des signaux intermédiaires (contact, vitesse vers la balle...)
- **Curriculum learning** : introduire ces signaux progressivement, sans dégrader les acquis des paliers précédents

Une introduction simultanée de tous les signaux converge plus lentement.

Reward hacking



Reward hacking (suite)

Comportement observé

Les deux agents collaborent pour faire osciller la balle entre les deux buts, maximisant leur récompense individuelle sans jamais chercher à marquer.

Reward hacking (suite)

Comportement observé

Les deux agents collaborent pour faire osciller la balle entre les deux buts, maximisant leur récompense individuelle sans jamais chercher à marquer.

Correction : reformulation en récompense *zero-sum* — le gain de l'un devient nécessairement la perte de l'autre

PPO vs SAC : une divergence marquée

- **PPO** : progresse de manière cohérente à travers tout le curriculum
- **SAC** : stagne dès le Palier I, entraînement interrompu

Deux facteurs explicatifs :

PPO vs SAC : une divergence marquée

- **PPO** : progresse de manière cohérente à travers tout le curriculum
- **SAC** : stagne dès le Palier I, entraînement interrompu

Deux facteurs explicatifs :

- ① Limites d'implémentation de `rlgym-sac` (pas de gradient clipping, cible d'entropie fixe)

PPO vs SAC : une divergence marquée

- **PPO** : progresse de manière cohérente à travers tout le curriculum
- **SAC** : stagne dès le Palier I, entraînement interrompu

Deux facteurs explicatifs :

- ① Limites d'implémentation de `rlgym-sac` (pas de gradient clipping, cible d'entropie fixe)
- ② Espace d'actions **continu brut** (8 dimensions) contre l'espace **discret curaté** (90 actions) de PPO

PPO vs SAC : une divergence marquée

- **PPO** : progresse de manière cohérente à travers tout le curriculum
- **SAC** : stagne dès le Palier I, entraînement interrompu

Deux facteurs explicatifs :

- ① Limites d'implémentation de `rlgym-sac` (pas de gradient clipping, cible d'entropie fixe)
- ② Espace d'actions **continu brut** (8 dimensions) contre l'espace **discret curaté** (90 actions) de PPO

Résultat

Impossible de conclure à une infériorité intrinsèque de SAC sur cet environnement.

Résultats de l'agent PPO

- Victoires **3-0** contre Element (finaliste RLBot 2022)

Résultats de l'agent PPO

- Victoires **3-0** contre Element (finaliste RLBot 2022)
- Victoires **3-0** contre Necto (vainqueur RLBot 2022, entraîné sur 3 modes de jeu et un budget supérieur)

Résultats de l'agent PPO

- Victoires **3-0** contre Element (finaliste RLBot 2022)
- Victoires **3-0** contre Necto (vainqueur RLBot 2022, entraîné sur 3 modes de jeu et un budget supérieur)
- **6 victoires sur 9** contre des joueurs humains (Or à Champion)

- Victoires **3-0** contre Element (finaliste RLBot 2022)
- Victoires **3-0** contre Necto (vainqueur RLBot 2022, entraîné sur 3 modes de jeu et un budget supérieur)
- **6 victoires sur 9** contre des joueurs humains (Or à Champion)

Comportements émergents non récompensés explicitement :

- Gestion du boost plus économe qu'un joueur humain

Résultats de l'agent PPO

- Victoires **3-0** contre Element (finaliste RLBot 2022)
- Victoires **3-0** contre Necto (vainqueur RLBot 2022, entraîné sur 3 modes de jeu et un budget supérieur)
- **6 victoires sur 9** contre des joueurs humains (Or à Champion)

Comportements émergents non récompensés explicitement :

- Gestion du boost plus économe qu'un joueur humain
- Utilisation systématique et précoce du *powerslide*

Limites et perspectives

- **Phase I** : seulement **5 seeds** → écarts-types élevés (45 à 52 points), estimations encore bruitées

- **Phase I** : seulement **5 seeds** → écarts-types élevés (45 à 52 points), estimations encore bruitées
- **Phase II** : aucun tuning systématique des hyperparamètres (coût computationnel prohibitif à cette échelle + complexité avec le curriculum)

- **Phase I** : seulement **5 seeds** → écarts-types élevés (45 à 52 points), estimations encore bruitées
- **Phase II** : aucun tuning systématique des hyperparamètres (coût computationnel prohibitif à cette échelle + complexité avec le curriculum)
- **Comparaison PPO/SAC sur Rocket League** : non tranchée — limites d'implémentation vs limites intrinsèques de l'algorithme

- **Phase I** : seulement **5 seeds** → écarts-types élevés (45 à 52 points), estimations encore bruitées
- **Phase II** : aucun tuning systématique des hyperparamètres (coût computationnel prohibitif à cette échelle + complexité avec le curriculum)
- **Comparaison PPO/SAC sur Rocket League** : non tranchée — limites d'implémentation vs limites intrinsèques de l'algorithme

À retenir

Un score d'optimisation ou un résultat isolé ne suffit jamais à conclure seul — la validation multi-seeds et la prudence d'interprétation restent essentielles.

- ① **Corriger l'implémentation SAC** : gradient clipping, standardisation effective des retours → trancher réellement la comparaison avec PPO

- ① **Corriger l'implémentation SAC** : gradient clipping, standardisation effective des retours → trancher réellement la comparaison avec PPO
- ② **Apprentissage par imitation** (Video PreTraining) : initialiser l'agent à partir de replays humains plutôt que d'une politique aléatoire

- ① **Corriger l'implémentation SAC** : gradient clipping, standardisation effective des retours → trancher réellement la comparaison avec PPO
- ② **Apprentissage par imitation** (Video PreTraining) : initialiser l'agent à partir de replays humains plutôt que d'une politique aléatoire
- ③ **Entraînement multi-agent** : généraliser au 2v2/3v3 et diversifier les partenaires d'entraînement (*league training*)

Conclusion

Conclusion

Explorer un domaine riche et vaste : de la sélection d'algorithmes standards à la conception d'un signal de récompense pour un environnement avancé.

Explorer un domaine riche et vaste : de la sélection d'algorithmes standards à la conception d'un signal de récompense pour un environnement avancé.

- **Aucun algorithme universel** : dépend de l'espace d'actions, du budget de calcul et de l'environnement — bien plus que d'un score de tuning isolé

Explorer un domaine riche et vaste : de la sélection d'algorithmes standards à la conception d'un signal de récompense pour un environnement avancé.

- **Aucun algorithme universel** : dépend de l'espace d'actions, du budget de calcul et de l'environnement — bien plus que d'un score de tuning isolé
- La rareté du signal de récompense **peut être surmontée** par la combinaison du *reward shaping* et du *curriculum learning*...

Explorer un domaine riche et vaste : de la sélection d'algorithmes standards à la conception d'un signal de récompense pour un environnement avancé.

- **Aucun algorithme universel** : dépend de l'espace d'actions, du budget de calcul et de l'environnement — bien plus que d'un score de tuning isolé
- La rareté du signal de récompense **peut être surmontée** par la combinaison du *reward shaping* et du *curriculum learning*...
- ...à condition de rester vigilant face au risque de *reward hacking* qu'elle introduit

Conclusion (suite)

En résumé

Du hasard d'un agent qui ne marque jamais, à un agent qui bat des joueurs de niveau Champion : la démonstration qu'un signal de récompense bien conçu peut faire toute la différence.

Merci !

Références bibliographiques I

- AKIBA, Takuya ; SANO, Shotaro ; YANASE, Toshihiko ; OHTA, Takeru ; KOYAMA, Masanori, 2019. *Optuna : A Next-generation Hyperparameter Optimization Framework* [en ligne]. 2019-07-25. [visité le 04/05/2026]. Disp. à l'adr. DOI : 10.48550/arXiv.1907.10902.
- BAKER, Bowen ; AKKAYA, Ilge ; ZHOKHOV, Peter ; HUIZINGA, Joost ; TANG, Jie ; ECOFFET, Adrien ; HOUGHTON, Brandon ; SAMPEDRO, Raul ; CLUNE, Jeff, 2022. *Video PreTraining (VPT) : Learning to Act by Watching Unlabeled Online Videos* [en ligne]. 2022-06-23. [visité le 08/07/2026]. Disp. à l'adr. DOI : 10.48550/arXiv.2206.11795.
- FARAMA FOUNDATION, 2025. *Gymnasium Documentation - Lunar Lander* [en ligne]. [visité le 05/04/2026]. Disp. à l'adr.: https://gymnasium.farama.org/environments/box2d/lunar_lander.html.

Références bibliographiques II

HAARNOJA, Tuomas ; ZHOU, Aurick ; ABBEEL, Pieter ; LEVINE, Sergey, 2018. *Soft Actor-Critic : Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor* [en ligne]. 2018-08-08. [visité le 31/03/2026]. Disp. à l'adr. DOI : 10.48550/arXiv.1801.01290.

LITTMAN, Michael L., 1994. Markov Games as a Framework for Multi-Agent Reinforcement Learning. In : COHEN, William W. ; HIRSH, Haym (éd.). *Machine Learning Proceedings 1994* [en ligne]. San Francisco (CA) : Morgan Kaufmann, p. 157-163 [visité le 22/06/2026]. ISBN 978-1-55860-335-6. Disp. à l'adr. DOI : 10.1016/B978-1-55860-335-6.50027-1.

Références bibliographiques III

- MNIH, Volodymyr; KAVUKCUOGLU, Koray; SILVER, David; RUSU, Andrei A.; VENESS, Joel; BELLEMARE, Marc G.; GRAVES, Alex; RIEDMILLER, Martin; FIDJELAND, Andreas K.; OSTROVSKI, Georg; PETERSEN, Stig; BEATTIE, Charles; SADIK, Amir; ANTONOGLU, Ioannis; KING, Helen; KUMARAN, Dharshan; WIERSTRA, Daan; LEGG, Shane; HASSABIS, Demis, 2015. Human-Level Control through Deep Reinforcement Learning. *Nature* [en ligne]. Vol. 518, no. 7540, p. 529–533 [visité le 03/31/2026]. ISSN 1476-4687. Disp. à l'adr. DOI: 10.1038/nature14236.
- NARVEKAR, Sanmit; PENG, Bei; LEONETTI, Matteo; SINAPOV, Jivko; TAYLOR, Matthew E.; STONE, Peter, 2020. *Curriculum Learning for Reinforcement Learning Domains : A Framework and Survey* [en ligne]. 2020-09-17. [visité le 22/06/2026]. Disp. à l'adr. DOI : 10.48550/arXiv.2003.04960.

Références bibliographiques IV

RLBot Championship 2022, 2022 [en ligne]. [visit  le 02/07/2026]. Disp.   l'adr. : <https://www.youtube.com/watch?v=XVIxZA6gFRI>.

SCHULMAN, John; WOLSKI, Filip; DHARIWAL, Prafulla;
RADFORD, Alec; KLIMOV, Oleg, 2017. *Proximal Policy Optimization Algorithms* [en ligne]. arXiv.org, 2017-07-20. [visit  le 03/31/2026].
Disp.   l'adr.: <https://arxiv.org/abs/1707.06347v2>.

- Rapport WandB sur LunarLander
- Vidéos de comparaison des agents DQN, PPO et SAC sur LunarLander
- Replays des parties de l'agent PPO sur Rocket League
- Explication de pitch, yaw et roll