

Soutenance de mémoire - Master IS

*Exploration des concepts et des techniques d'apprentissage par
renforcement : De la théorie à la pratique*

David Paulino

21 août 2026


Plan de la présentation

- 1 Introduction
- 2 Fondations minimales
- 3 Phase I
- 4 Phase II
- 5 Limites et perspectives
- 6 Conclusion

Introduction


Contexte

Rocket League : un jeu de football avec des voitures.



Contexte

Rocket League : un jeu de football avec des voitures.




Question

Quelle est la probabilité qu'un agent agissant aléatoirement parvienne à marquer un but dans ce jeu ?

Contexte

Rocket League : un jeu de football avec des voitures.



Question

Quelle est la probabilité qu'un agent agissant aléatoirement parvienne à marquer un but dans ce jeu ?

Quasi nulle.

Le problème du *sparse reward*

Ce phénomène porte un nom : le **sparse reward**

Ce phénomène porte un nom : le **sparse reward**

- Quand l'objectif final n'est atteint que rarement (voire jamais au début), l'agent ne reçoit presque aucun signal exploitable.

Ce phénomène porte un nom : le **sparse reward**

- Quand l'objectif final n'est atteint que rarement (voire jamais au début), l'agent ne reçoit presque aucun signal exploitable.
- Résultat : **absence totale d'apprentissage observable**, même après des millions de pas d'entraînement.

Problématique

Comment mener à bien l'apprentissage par renforcement dans un environnement à récompense rare, de la sélection et du réglage d'algorithmes standards jusqu'à la conception d'un signal de récompense pour un environnement avancé ?

Deux axes complémentaires :

Problématique

Comment mener à bien l'apprentissage par renforcement dans un environnement à récompense rare, de la sélection et du réglage d'algorithmes standards jusqu'à la conception d'un signal de récompense pour un environnement avancé ?

Deux axes complémentaires :

- ❶ **Sélection et optimisation des modèles** : quel algorithme choisir (DQN, PPO, SAC) selon l'environnement, et comment régler ses hyperparamètres ?
- ❷ **Construction du signal de récompense** : comment densifier un signal rare sans dénaturer la tâche — et quel risque cela introduit ?

Démarche en deux phases


- ① **Phase I** — Validation méthodologique sur un environnement plus simple *LunarLander* : comparaison DQN / PPO / SAC, optimisation Optuna, robustesse multi-seeds.

Démarche en deux phases

- ① **Phase I** — Validation méthodologique sur un environnement plus simple *LunarLander* : comparaison DQN / PPO / SAC, optimisation Optuna, robustesse multi-seeds.
- ② **Phase II** — Retour à **Rocket League** : reward shaping et curriculum learning pour surmonter la rareté structurelle du signal.

Fondations minimales

Boucle agent-environnement



Comparaison des algorithmes

Tableau comparatif des caractéristiques principales de DQN, PPO et SAC.

Caractéristique	DQN	PPO	SAC
Paradigme	Off-policy	On-policy	Off-policy
Espace d'actions	Discret	Les deux	Continu
Sample efficiency	Moyenne	Faible	Élevée

Phase I

- **Environnement** : LunarLander
- **Algorithmes** : DQN, PPO, SAC
- **Optimisation** : Optuna pour le tuning des hyperparamètres
- **Évaluation** : Multi-seeds pour la robustesse

Score de tuning vs robustesse réelle

Combinaison	Score Optuna	Éval. finale (moy.)	Seeds résolues
DQN discret	275.14	145.19	1/5
PPO discret	278.76	218.58	3/5
PPO continu	280.42	208.67	2/5
SAC continu	284.05	233.44	4/5

Score de tuning vs robustesse réelle

Combinaison	Score Optuna	Éval. finale (moy.)	Seeds résolues
DQN discret	275.14	145.19	1/5
PPO discret	278.76	218.58	3/5
PPO continu	280.42	208.67	2/5
SAC continu	284.05	233.44	4/5

Enseignement clé

Le score de tuning n'est **pas un prédicteur fiable** de la robustesse : DQN a un très bon score, mais la pire performance finale.

Phase II

L'environnement Rocket League

- Simulation via **RocketSim** + **RLGym** : physique fidèle, entraînement *headless* (sans rendu graphique)
- Mode **1v1** : un agent affronte une copie de lui-même (*self-play*)
- Espace d'actions réduit par discrétisation : 1944 → **90** actions pertinentes
- Fréquence de décision ramenée de 120 Hz à **15 Hz** (*action repeat*)

L'environnement Rocket League

- Simulation via **RocketSim** + **RLGym** : physique fidèle, entraînement *headless* (sans rendu graphique)
- Mode **1v1** : un agent affronte une copie de lui-même (*self-play*)
- Espace d'actions réduit par discrétisation : 1944 → **90** actions pertinentes
- Fréquence de décision ramenée de 120 Hz à **15 Hz** (*action repeat*)

Rappel

Le seul signal naturel — marquer un but — est **extrêmement rare** : aucun apprentissage observable en RL pur.

Reward shaping et curriculum

Palier	Objectif
I	Contrôle de base et contact avec la balle
II	Apprentissage du score (introduction du but)
III	Perfectionnement mécanique (boost, aérien, kickoff)

- **Reward shaping** : densifier le signal rare avec des signaux intermédiaires (contact, vitesse vers la balle...)
- **Curriculum learning** : introduire ces signaux progressivement, sans dégrader les acquis des paliers précédents

Reward shaping et curriculum

Palier	Objectif
I	Contrôle de base et contact avec la balle
II	Apprentissage du score (introduction du but)
III	Perfectionnement mécanique (boost, aérien, kickoff)

- **Reward shaping** : densifier le signal rare avec des signaux intermédiaires (contact, vitesse vers la balle...)
- **Curriculum learning** : introduire ces signaux progressivement, sans dégrader les acquis des paliers précédents

Une introduction simultanée de tous les signaux converge plus lentement.

Reward hacking



Reward hacking (suite)

Observation

Collaboration → oscillation de la balle entre les deux buts, maximisant leur récompense individuelle sans jamais marquer.

Reward hacking (suite)

Observation

Collaboration → oscillation de la balle entre les deux buts, maximisant leur récompense individuelle sans jamais marquer.

Correction : reformulation en récompense *zero-sum* — le gain de l'un devient nécessairement la perte de l'autre

Reward hacking (suite)

Observation

Collaboration → oscillation de la balle entre les deux buts, maximisant leur récompense individuelle sans jamais marquer.

Correction : reformulation en récompense *zero-sum* — le gain de l'un devient nécessairement la perte de l'autre

Grande importance à la visualisation ponctuelle de l'agent pour éviter ce genre de dérives.

PPO vs SAC : une divergence marquée

- **PPO** : progresse de manière cohérente à travers tout le curriculum
- **SAC** : stagne dès le Palier I, entraînement interrompu

Deux facteurs explicatifs :

PPO vs SAC : une divergence marquée

- **PPO** : progresse de manière cohérente à travers tout le curriculum
- **SAC** : stagne dès le Palier I, entraînement interrompu

Deux facteurs explicatifs :

- ① Limites d'implémentation de `rlgym-sac` (pas de gradient clipping, cible d'entropie fixe)

PPO vs SAC : une divergence marquée

- **PPO** : progresse de manière cohérente à travers tout le curriculum
- **SAC** : stagne dès le Palier I, entraînement interrompu

Deux facteurs explicatifs :

- ① Limites d'implémentation de `rlgym-sac` (pas de gradient clipping, cible d'entropie fixe)
- ② Espace d'actions **continu brut** (8 dimensions) contre l'espace **discret curaté** (90 actions) de PPO

PPO vs SAC : une divergence marquée

- **PPO** : progresse de manière cohérente à travers tout le curriculum
- **SAC** : stagne dès le Palier I, entraînement interrompu

Deux facteurs explicatifs :

- ① Limites d'implémentation de `rlgym-sac` (pas de gradient clipping, cible d'entropie fixe)
- ② Espace d'actions **continu brut** (8 dimensions) contre l'espace **discret curaté** (90 actions) de PPO

Résultat

Impossible de conclure à une infériorité intrinsèque de SAC sur cet environnement.

Résultats de l'agent PPO

- Victoires **3-0** contre Element (finaliste RLBot 2022)
- Victoires **3-0** contre Necto (vainqueur RLBot 2022, entraîné sur 3 modes de jeu et un budget supérieur)
- **6 victoires sur 9** contre des joueurs humains (Or à Champion).
79 buts marqués contre **51 encaissés**.

Résultats de l'agent PPO

- Victoires **3-0** contre Element (finaliste RLBot 2022)
- Victoires **3-0** contre Necto (vainqueur RLBot 2022, entraîné sur 3 modes de jeu et un budget supérieur)
- **6 victoires sur 9** contre des joueurs humains (Or à Champion).
79 buts marqués contre 51 encaissés.

Comportements émergents non récompensés explicitement :

- Gestion du boost plus économe qu'un joueur humain
- Utilisation systématique et précoce du *powerslide*

Limites et perspectives

- **Phase I** : seulement **5 seeds** → écarts-types élevés (45 à 52 points), estimations encore bruitées
- **Phase II** : aucun tuning systématique des hyperparamètres (coût computationnel prohibitif à cette échelle + complexité avec le curriculum)
- **Comparaison PPO/SAC sur Rocket League** : non tranchée — limites d'implémentation vs limites intrinsèques de l'algorithme

- **Phase I** : seulement **5 seeds** → écarts-types élevés (45 à 52 points), estimations encore bruitées
- **Phase II** : aucun tuning systématique des hyperparamètres (coût computationnel prohibitif à cette échelle + complexité avec le curriculum)
- **Comparaison PPO/SAC sur Rocket League** : non tranchée — limites d'implémentation vs limites intrinsèques de l'algorithme

À retenir

Un score d'optimisation ou un résultat isolé ne suffit jamais à conclure seul — la validation multi-seeds et la prudence d'interprétation restent essentielles.

- ① **Corriger l'implémentation SAC** : gradient clipping, standardisation effective des retours → trancher réellement la comparaison avec PPO
- ② **Apprentissage par imitation** (Video PreTraining) : initialiser l'agent à partir de replays humains plutôt que d'une politique aléatoire
- ③ **Entraînement multi-agent** : généraliser au 2v2/3v3 et diversifier les partenaires d'entraînement (*league training*)

Conclusion

Conclusion

Explorer un domaine riche et vaste : de la sélection d'algorithmes standards à la conception d'un signal de récompense pour un environnement avancé.

Explorer un domaine riche et vaste : de la sélection d'algorithmes standards à la conception d'un signal de récompense pour un environnement avancé.

- **Aucun algorithme universel** : dépend de l'espace d'actions, du budget de calcul et de l'environnement — bien plus que d'un score de tuning isolé

Explorer un domaine riche et vaste : de la sélection d'algorithmes standards à la conception d'un signal de récompense pour un environnement avancé.

- **Aucun algorithme universel** : dépend de l'espace d'actions, du budget de calcul et de l'environnement — bien plus que d'un score de tuning isolé
- La rareté du signal de récompense **peut être surmontée** par la combinaison du *reward shaping* et du *curriculum learning*...

Explorer un domaine riche et vaste : de la sélection d'algorithmes standards à la conception d'un signal de récompense pour un environnement avancé.

- **Aucun algorithme universel** : dépend de l'espace d'actions, du budget de calcul et de l'environnement — bien plus que d'un score de tuning isolé
- La rareté du signal de récompense **peut être surmontée** par la combinaison du *reward shaping* et du *curriculum learning*...
- ...à condition de rester vigilant face au risque de *reward hacking* qu'elle introduit

Conclusion (suite)

En résumé

Du hasard d'un agent qui ne marque jamais, à un agent qui bat des joueurs de niveau Champion : la démonstration qu'un signal de récompense bien conçu peut faire toute la différence.

Merci !

Références bibliographiques I

- AKIBA, Takuya ; SANO, Shotaro ; YANASE, Toshihiko ; OHTA, Takeru ; KOYAMA, Masanori, 2019. *Optuna : A Next-generation Hyperparameter Optimization Framework* [en ligne]. 2019-07-25. [visité le 04/05/2026]. Disp. à l'adr. DOI : 10.48550/arXiv.1907.10902.
- BAKER, Bowen ; AKKAYA, Ilge ; ZHOKHOV, Peter ; HUIZINGA, Joost ; TANG, Jie ; ECOFFET, Adrien ; HOUGHTON, Brandon ; SAMPEDRO, Raul ; CLUNE, Jeff, 2022. *Video PreTraining (VPT) : Learning to Act by Watching Unlabeled Online Videos* [en ligne]. 2022-06-23. [visité le 08/07/2026]. Disp. à l'adr. DOI : 10.48550/arXiv.2206.11795.
- FARAMA FOUNDATION, 2025. *Gymnasium Documentation - Lunar Lander* [en ligne]. [visité le 05/04/2026]. Disp. à l'adr.: https://gymnasium.farama.org/environments/box2d/lunar_lander.html.

Références bibliographiques II

HAARNOJA, Tuomas ; ZHOU, Aurick ; ABBEEL, Pieter ; LEVINE, Sergey, 2018. *Soft Actor-Critic : Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor* [en ligne]. 2018-08-08. [visité le 31/03/2026]. Disp. à l'adr. DOI : 10.48550/arXiv.1801.01290.

LITTMAN, Michael L., 1994. Markov Games as a Framework for Multi-Agent Reinforcement Learning. In : COHEN, William W. ; HIRSH, Haym (éd.). *Machine Learning Proceedings 1994* [en ligne]. San Francisco (CA) : Morgan Kaufmann, p. 157-163 [visité le 22/06/2026]. ISBN 978-1-55860-335-6. Disp. à l'adr. DOI : 10.1016/B978-1-55860-335-6.50027-1.

Références bibliographiques III

- MNIH, Volodymyr; KAVUKCUOGLU, Koray; SILVER, David; RUSU, Andrei A.; VENESS, Joel; BELLEMARE, Marc G.; GRAVES, Alex; RIEDMILLER, Martin; FIDJELAND, Andreas K.; OSTROVSKI, Georg; PETERSEN, Stig; BEATTIE, Charles; SADIK, Amir; ANTONOGLU, Ioannis; KING, Helen; KUMARAN, Dharshan; WIERSTRA, Daan; LEGG, Shane; HASSABIS, Demis, 2015. Human-Level Control through Deep Reinforcement Learning. *Nature* [en ligne]. Vol. 518, no. 7540, p. 529–533 [visité le 03/31/2026]. ISSN 1476-4687. Disp. à l'adr. DOI: 10.1038/nature14236.
- NARVEKAR, Sanmit; PENG, Bei; LEONETTI, Matteo; SINAPOV, Jivko; TAYLOR, Matthew E.; STONE, Peter, 2020. *Curriculum Learning for Reinforcement Learning Domains : A Framework and Survey* [en ligne]. 2020-09-17. [visité le 22/06/2026]. Disp. à l'adr. DOI : 10.48550/arXiv.2003.04960.

Références bibliographiques IV

RLBot Championship 2022, 2022 [en ligne]. [visit  le 02/07/2026]. Disp.   l'adr. : <https://www.youtube.com/watch?v=XVIxZA6gFRI>.

SCHULMAN, John; WOLSKI, Filip; DHARIWAL, Prafulla;
RADFORD, Alec; KLIMOV, Oleg, 2017. *Proximal Policy Optimization Algorithms* [en ligne]. arXiv.org, 2017-07-20. [visit  le 03/31/2026].
Disp.   l'adr.: <https://arxiv.org/abs/1707.06347v2>.

- Rapport WandB sur LunarLander
- Vidéos de comparaison des agents DQN, PPO et SAC sur LunarLander
- Replays des parties de l'agent PPO sur Rocket League
- Explication de pitch, yaw et roll