

Soutenance de mémoire - Master IS

*Exploration des concepts et des techniques d'apprentissage par
renforcement : De la théorie à la pratique*

David Paulino

21 août 2026


Plan de la présentation

- 1 Introduction
- 2 Fondations minimales
- 3 Phase II
- 4 Limites et perspectives
- 5 Conclusion

Introduction


Contexte

Rocket League : un jeu de football avec des voitures.



Contexte


Rocket League : un jeu de football avec des voitures.



Quelle est la probabilité qu'un agent agissant aléatoirement parvienne à marquer un but dans ce jeu ?

Contexte

Rocket League : un jeu de football avec des voitures.



Quelle est la probabilité qu'un agent agissant aléatoirement parvienne à marquer un but dans ce jeu ?

Quasi nulle.

Le problème du *sparse reward*

Ce phénomène porte un nom : le **sparse reward**

Le problème du *sparse reward*

Ce phénomène porte un nom : le **sparse reward**

- Objectif atteint rarement (voire jamais au début) → presque aucun signal exploitable
- Résultat : aucun apprentissage observable, même après des millions de pas d'entraînement

Problématique

Comment mener l'apprentissage par renforcement dans un environnement à récompense rare, de la sélection d'algorithmes standards jusqu'à la conception d'un signal de récompense pour un environnement avancé ?

Problématique

Comment mener l'apprentissage par renforcement dans un environnement à récompense rare, de la sélection d'algorithmes standards jusqu'à la conception d'un signal de récompense pour un environnement avancé ?

- ❶ **Sélection et optimisation des modèles** : quel algorithme, quels hyperparamètres ?
- ❷ **Construction du signal de récompense** : comment densifier un signal rare sans dénaturer la tâche ?

Démarche en deux phases


- 1 **Phase I** — Validation méthodologique sur *LunarLander* : DQN / PPO / SAC, Optuna, multi-seeds.

Démarche en deux phases

- ① **Phase I** — Validation méthodologique sur *LunarLander* : DQN / PPO / SAC, Optuna, multi-seeds.
- ② **Phase II** — Retour à **Rocket League** : reward shaping et curriculum learning.

Fondations minimales

Boucle agent-environnement



Comparaison des algorithmes

Caractéristique	DQN	PPO	SAC
Paradigme	Off-policy	On-policy	Off-policy
Espace d'actions	Discret	Les deux	Continu
Sample efficiency	Moyenne	Faible	Élevée

Un enseignement clé avant la Phase II

Sur **LunarLander** : DQN, PPO, SAC, optimisation Optuna, évaluation multi-seeds.

Un enseignement clé avant la Phase II

Sur **LunarLander** : DQN, PPO, SAC, optimisation Optuna, évaluation multi-seeds.

Score de tuning élevé $\neq$ robustesse : DQN, malgré un excellent score Optuna (275), s'effondre en évaluation finale (145, 1 seed sur 5 résolue).

Phase II

L'environnement Rocket League

- **RocketSim + RLGym** : physique fidèle, entraînement *headless*
- `rlgym-ppo` et `rlgym-sac` : forks vectorisés, conçus pour l'entraînement à grande échelle (milliards de steps)
- Pas d'équivalent vectorisé pour DQN → écarté pour la Phase II
- Mode **1v1**, *self-play*
- Espace d'actions réduit : 1944 → **90** actions (PPO)
- Décision ramenée de 120 Hz à **15 Hz**

Reward shaping et curriculum

Palier	Objectif
I	Contrôle de base et contact avec la balle
II	Apprentissage du score
III	Perfectionnement mécanique


- **Reward shaping** : signaux intermédiaires (contact, vitesse vers la balle...)
- **Curriculum learning** : introduction progressive, sans dégrader les acquis

Reward hacking

Contexte

$R = \text{toucher la balle} + v_{\text{balle} \rightarrow \text{but adverse}}$

(Récompense individuelle)



Reward hacking (suite)

Problématique

Collaboration → oscillation de la balle entre les deux buts, sans jamais marquer.

Reward hacking (suite)

Problématique

Collaboration → oscillation de la balle entre les deux buts, sans jamais marquer.

Correction : récompense *zero-sum* — le gain de l'un devient la perte de l'autre

PPO vs SAC : une divergence marquée

- **PPO** : progresse à travers tout le curriculum
- **SAC** : stagne dès le Palier I, entraînement interrompu

Deux facteurs explicatifs :

- ① Limites d'implémentation de `rlgym-sac`
- ② Espace continu brut (8 dim.) contre espace discret curaté (90 actions) pour PPO

Résultats de l'agent PPO

- **3 matchs gagnés, 0 perdus** contre Element (finaliste RLBot 2022)
- **3 matchs gagnés, 0 perdus** contre Necto (vainqueur RLBot 2022, budget supérieur)
- **6 victoires sur 9** contre des joueurs humains (Or à Champion) — 79 buts marqués, 51 encaissés

Résultats de l'agent PPO

- **3 matchs gagnés, 0 perdus** contre Element (finaliste RLBot 2022)
- **3 matchs gagnés, 0 perdus** contre Necto (vainqueur RLBot 2022, budget supérieur)
- **6 victoires sur 9** contre des joueurs humains (Or à Champion) — 79 buts marqués, 51 encaissés

Comportements émergents non récompensés :

- Gestion du boost plus économe qu'un joueur humain
- Usage systématique et précoce du *powerslide*
- Apprentissage du *flick*

Limites et perspectives

- **Phase I** : 5 seeds seulement → écarts-types élevés, estimations bruitées
- **Phase II** : aucun tuning systématique des hyperparamètres (coût prohibitif à cette échelle)
- **PPO vs SAC** : comparaison non tranchée

- ❶ **Corriger l'implémentation SAC** pour trancher réellement la comparaison
- ❷ **Apprentissage par imitation** (Video PreTraining) à partir de replays humains
- ❸ **Entraînement multi-agent** : 2v2/3v3, diversification des partenaires (*league training*)

Conclusion

- **Aucun algorithme universel** : dépend de l'espace d'actions, du budget de calcul et de l'environnement
- La rareté du signal **peut être surmontée** par reward shaping et curriculum learning, à **condition** de rester vigilant face au reward hacking

- **Aucun algorithme universel** : dépend de l'espace d'actions, du budget de calcul et de l'environnement
- La rareté du signal **peut être surmontée** par reward shaping et curriculum learning, à **condition** de rester vigilant face au reward hacking

Du hasard d'un agent qui ne marque jamais, à un agent qui bat des joueurs de niveau Champion.

Merci pour votre attention !

Références bibliographiques I

BAKER, Bowen ; AKKAYA, Ilge ; ZHOKHOV, Peter ; HUIZINGA, Joost ; TANG, Jie ; ECOFFET, Adrien ; HOUGHTON, Brandon ; SAMPEDRO, Raul ; CLUNE, Jeff, 2022. *Video PreTraining (VPT) : Learning to Act by Watching Unlabeled Online Videos* [en ligne]. 2022-06-23. [visit  le 08/07/2026]. Disp.   l'adr. DOI : 10.48550/arXiv.2206.11795.

LITTMAN, Michael L., 1994. Markov Games as a Framework for Multi-Agent Reinforcement Learning. In : COHEN, William W. ; HIRSH, Haym ( d.). *Machine Learning Proceedings 1994* [en ligne]. San Francisco (CA) : Morgan Kaufmann, p. 157-163 [visit  le 22/06/2026]. ISBN 978-1-55860-335-6. Disp.   l'adr. DOI : 10.1016/B978-1-55860-335-6.50027-1.

Références bibliographiques II

- NARVEKAR, Sanmit ; PENG, Bei ; LEONETTI, Matteo ; SINAPOV, Jivko ; TAYLOR, Matthew E. ; STONE, Peter, 2020. *Curriculum Learning for Reinforcement Learning Domains : A Framework and Survey* [en ligne]. 2020-09-17. [visit  le 22/06/2026]. Disp.   l'adr. DOI : 10.48550/arXiv.2003.04960.
- RLBot Championship 2022*, 2022 [en ligne]. [visit  le 02/07/2026]. Disp.   l'adr. : <https://www.youtube.com/watch?v=XVIxZA6gFRI>.

- Rapport WandB sur LunarLander
- Vidéos de comparaison des agents DQN, PPO et SAC sur LunarLander
- Replays des parties de l'agent PPO sur Rocket League
- Explication de pitch, yaw et roll